

METODOLOGIE PENTRU ESTIMAREA NEREGULARITĂȚILOR PROBABILE ALE PROCESULUI DE LIPIRE PE BAZA MORFOLOGIEI VOIDURILOR IDENTIFICATE ÎN IMAGINI CU RAZE X ALE ÎMBINĂRILOR BGA

Candidat: Andrei, Matală

Coordonator științific: Conf.dr.ing. Raul, Ionel

Sesiunea: Iunie 2026

Anexa 1

Nume și prenume student: **Matală Andrei**

Nume și prenume coordonator: **IONEL RAUL**

Titlul lucrării: **Metode AOI pentru validarea calității PCB-urilor**

Compania: -

Coordonator din partea companiei: -

Lucrarea trebuie finalizată ca:

- studiu teoretic
- implementare de metodă/algorithm într-un limbaj de programare

Structură lucrare:

I. INTRODUCERE

II. STATE OF THE ART

III. IMPLEMENTĂRI AOI FOLOSIND PROCESARE DE IMAGINE ȘI ÎNVĂȚARE
AUTOMATĂ

IV. REZULTATE EXPERIMENTALE

V. CONCLUZII

VI. BIBLIOGRAFIE

* Structura poate suferi modificări ulterioare în funcție de progresul lucrării; aceasta reprezintă doar o bază orientativă.

Data: 23.11.2025

Semnătură coordonator:

Semnătură student:

Anexa2

Nume și prenume student: **Matală Andrei**

Scopul lucrării:

Scopul lucrării este dezvoltarea unei metode automate și explicabile pentru detecția și evaluarea voidurilor din îmbinările BGA, utilizând imagini obținute prin inspecție cu raze X. Lucrarea urmărește identificarea regiunii BGA, detectarea pad-urilor/solder balls și analizarea zonelor interne ale acestora pentru determinarea voidurilor și calculul procentului de voiding. Prin această abordare, se dorește obținerea unei evaluări cantitative și calitative a calității lipiturilor, care poate contribui la identificarea unor posibile neregularități ale procesului de lipire și la îmbunătățirea controlului nedistructiv în industria electronică.

Cuvinte cheie:

BGA, detecția voidurilor, inspecție cu raze X, procesarea imaginilor, procent de voiding

Cuprinsul proiectului (titluri capitole):

1. Introducere
 - 1.1 Contextul inspecției calității în industria electronică
 - 1.2 Importanța îmbinărilor BGA în ansamblurile electronice
 - 1.3 Problema voidurilor în solder balls
 - 1.4 Necesitatea inspecției nedistructive cu raze X
 - 1.5 Obiectivele lucrării
 - 1.6 BGA în electronica biomedicală
2. Stadiul actual al cercetării
 - 2.1 Metode nedistructive utilizate în analiza îmbinărilor electronice
 - 2.2 Inspecția cu raze X și CT pentru componente microelectronice
 - 2.3 Defecte specifice îmbinărilor BGA
 - 2.4 Metode clasice și moderne de procesare a imaginilor pentru detecția defectelor
3. Fundament teoretic
 - 3.1 Caracteristici ale imaginilor X-ray pentru structuri BGA
 - 3.2 Preprocesarea imaginilor digitale
 - 3.3 Îmbunătățirea contrastului prin CLAHE
 - 3.4 Reducerea zgomotului prin filtrare mediană
 - 3.5 Detecția formelor circulare prin Hough Circle Transform
 - 3.6 Segmentarea imaginilor prin thresholding adaptiv
 - 3.7 Operații morfologice: opening și closing
 - 3.8 Connected Component Analysis
 - 3.9 Calculul procentului de voiding
4. Metodologia propusă
 - 4.1 Prezentarea generală a fluxului algoritmic
 - 4.2 Organizarea setului de imagini X-ray
 - 4.3 Detectarea automată a regiunii BGA
 - 4.4 Delimitarea ROI-ului BGA
 - 4.5 Detecția grilei de pad-uri BGA 16 x 16
 - 4.6 Filtrarea candidaților falși
 - 4.7 Regularizarea geometrică a pozițiilor pad-urilor
 - 4.8 Extragerea regiunilor individuale pentru fiecare solder ball
 - 4.9 Segmentarea voidurilor în interiorul fiecărui pad
 - 4.10 Rafinarea măștilor de voiduri

4.11	Calculul parametrilor cantitativi
4.12	Criterii pentru analiza calitativă a rezultatelor
5.	Implementarea aplicației software
5.1	Mediul de dezvoltare
5.2	Biblioteci utilizate
5.3	Diagrama fluxului de date
5.4	Modulele principale ale aplicației
5.5	Fluxul de intrare-ieșire al datelor
5.6	Generarea imaginilor intermediare
5.7	Generarea rapoartelor CSV / Excel
5.8	Considerații privind reproductibilitatea experimentelor
6.	Rezultate experimentale
6.1	Descrierea imaginilor utilizate pentru testare
6.2	Rezultate pentru detecția ROI-ului BGA
6.3	Rezultate pentru detecția pad-urilor BGA
6.4	Validarea grilei 16 x 16
6.5	Exemple de detecție a voidurilor
6.6	Calculul procentului de voiding
6.7	Analiza comparativă între imaginile PCBA1 și PCBA2
6.8	Cazuri dificile și limitări observate
6.9	Interpretarea rezultatelor din punct de vedere al calității lipirii
8.	Concluzii
8.1	Concluzii generale
8.2	Contribuții personale
8.3	Direcții viitoare de dezvoltare
	Bibliografie
	Anexe

Referințe bibliografice (3 lucrări semnificative):

- [1] M. A. Mercioni, C. D. Căleanu, and R. C. Ionel, "AI-Enhanced X-ray Computed Tomography for Microelectronics: A Brief Review of Machine Learning and Deep Learning Integration in Non-Destructive Failure Analysis," 2026.
- [2] J. C. Faes, M. N. Boone, J. Vijayakumar, N. Lammens, and W. Van Paepegem, "Quantitative, statistically robust characterization of solder joint geometry and voids in commercial BGA assemblies," in *Proc. 27th Int. Conf. Thermal, Mechanical and Multi-Physics Simulation and Experiments in Microelectronics and Microsystems (EuroSimE)*, 2026, doi: 10.1109/EuroSimE69483.2026.11511892.
- [3] P. Xiao, M. Xiao, N. Cai, B. Qiu, S. Zhou, and H. Wang, "Adaptive Hybrid Framework for Multiscale Void Inspection of Chip Resistor Solder Joints," *IEEE Transactions on Instrumentation and Measurement*, vol. 72, Art. no. 5004612, 2023, doi: 10.1109/TIM.2023.3235435.
- [4] H. Tang, W. Li, J. Nie, W. Liang, N. Cai, and J. Chen, "Multi-Scale Adaptive Inspection Framework for Voids in MOSFETs," *IEEE Transactions on Semiconductor Manufacturing*, vol. 38, no. 4, pp. 826-839, Nov. 2025, doi: 10.1109/TSM.2025.3604212.
- [5] O. Krammer, Á. Varga, A. Géczy, and K. Csorba, "Image Processing Methods for Detecting Voids in the Solder Joints of Surface-Mounted Components," in *Proc. 45th International Spring Seminar on Electronics Technology (ISSE)*, 2022, pp. 1-4, doi: 10.1109/ISSE54558.2022.9812775.
- [6] O. Kovac, T. Girasek, and A. Pietrikova, "Image Processing of Die Attach's X-Ray Images for Automatic Voids Detection and Evaluation," in *Proc. 39th International Spring Seminar on Electronics Technology (ISSE)*, 2016, pp. 199-203.
- [7] C. Cui, H. Wang, S. He, Z. Cai, Y. Zhao, and L. He, "An algorithm based on K-means for calculating void ratio of solder joint from X-ray image," in *Proc. 23rd International Conference on Electronic Packaging Technology (ICEPT)*, 2022, doi: 10.1109/ICEPT56209.2022.9873214.
- [8] T. Chvosta, K. Dušek, and T. Gurčík, "Occurrence of Voids in Soldered Joints for Electrical Engineering," in *Proc. 47th International Spring Seminar on Electronics Technology (ISSE)*, 2024, doi: 10.1109/ISSE61612.2024.10603930.
- [9] A. Alakayleh, M. E. A. Belhadi, S. Tahat, E. HMasha, A. Shmatok, A. Alahmer, and S. Hamasha, "Effect of Solder Paste Alloy and Volume on Solder Voiding," in *Proc. 22nd IEEE

- Intersociety Conference on Thermal and Thermomechanical Phenomena in Electronic Systems (ITherm)*, 2023, doi: 10.1109/ITHERM55368.2023.10177534.
- [10] S. P. Lim, K. O. Lee, K. Oi, Y. Yeo, K. Sweatman, T. Ono, K. Murayama, S. R. Martell, H. Shimamoto, and M. Tsuriya, "The Effects of Voids on Solder Joint Reliability in First Level Interconnect," in *Proc. 17th International Microsystems, Packaging, Assembly and Circuits Technology Conference (IMPACT)*, 2022, doi: 10.1109/IMPACT56280.2022.9966698.
- [11] L. Zhang, R. Wang, G. Zhong, Z. Chen, D. Diwu, and Z. Jin, "The Influence of Welding Interfacial Voids on the Thermal Conductivity of Space-borne High-power Electronics," in *Proc. 24th International Conference on Electronic Packaging Technology (ICEPT)*, 2023, doi: 10.1109/ICEPT59018.2023.10491912.
- [12] F. Wang and F. Wang, "Rapidly Void Detection in TSVs With 2-D X-Ray Imaging and Artificial Neural Networks," *IEEE Transactions on Semiconductor Manufacturing*, vol. 27, no. 2, pp. 246-251, May 2014, doi: 10.1109/TSM.2014.2309591.
- [13] M. H. Mohd Sa'at, M. H. Jamaluddin, M. I. M. Ameerudin, A. Z. Shukor, T. A. Izuddin, M. M. Ibrahim, and M. S. Sukiman, "Integration Artificial Intelligence with Conventional X-Ray Inspection for Improved Solder Void Detection in SSDC SiC Modules," in *Proc. IEEE International Conference on Artificial Intelligence in Engineering and Technology (IICAET)*, 2024, pp. 530-534, doi: 10.1109/IICAET62352.2024.10730272.
- [14] S. P. Prasad, C. Jois, and G. Subbarayan, "Novel Test Device for Non-destructive Experimental Characterization of Void Evolution in Microscale Solder Joints subjected to Thermal Aging," in *Proc. 21st IEEE Intersociety Conference on Thermal and Thermomechanical Phenomena in Electronic Systems (iTherm)*, 2022, doi: 10.1109/iTherm54085.2022.9899684.
- [15] S. P. Prasad, C. Jois, Y. Singh, G. Subbarayan, B. Penmecha, and P. Raghavan, "Void Growth and Intermetallic Bridging in Microscale Solder Interconnects Under Thermal Annealing," *IEEE Transactions on Components, Packaging and Manufacturing Technology*, vol. 14, no. 7, pp. 1308-1318, Jul. 2024, doi: 10.1109/TCPMT.2024.3416430.
- [16] Waygate Technologies, "Phoenix V|tome|x S240 microCT," Technical Brochure, Phoenix-Vtomex-S240-EN-BHPD31320-072020, 2020.

Activități desfășurate (o prezentare succintă, numerotată):

1. Începând cu mijlocul lunii aprilie, a fost stabilită direcția generală a lucrării, având ca temă detecția și evaluarea voidurilor din îmbinările BGA utilizând imagini obținute prin inspecție cu raze X.
2. A fost analizată importanța îmbinărilor BGA în ansamblurile electronice, inclusiv dificultatea inspecției acestora prin metode optice clasice, deoarece solder balls sunt poziționate sub componentă.
3. A fost documentată problema voidurilor în solder balls, fiind urmărite cauzele apariției acestora și influența lor asupra calității lipiturii, distribuției termice și fiabilității ansamblului electronic.
4. A fost începută documentarea teoretică privind metodele nedistructive de inspecție, cu accent pe utilizarea imaginilor X-ray și CT pentru analiza defectelor interne din componente microelectronice.
5. A fost realizată o analiză bibliografică inițială a articolelor științifice relevante pentru detecția voidurilor, procesarea imaginilor X-ray, analiza îmbinărilor BGA și metodele moderne de inspecție automată.
6. A fost stabilită metodologia principală a lucrării, pe baza recomandărilor primite: îmbunătățirea contrastului prin CLAHE, reducerea zgomotului prin filtru median, detecția pad-urilor prin Hough Circle Transform, segmentarea voidurilor prin thresholding adaptiv, rafinarea prin operații morfologice și evaluarea prin Connected Component Analysis.
7. A fost luată decizia ca lucrarea să folosească metode clasice și explicabile de procesare a imaginilor, fără utilizarea rețelelor neuronale, CNN, YOLO sau alte metode de machine learning/deep learning, deoarece problema are o structură geometrică relativ clară și repetitivă.
8. A fost definit scopul lucrării: realizarea unui algoritm capabil să identifice automat regiunea BGA, să detecteze pad-urile/solder balls, să analizeze voidurile din interiorul acestora și să calculeze procentul de voiding.
9. A fost organizat setul de imagini X-ray în foldere separate pentru imagini brute, imagini procesate, ROI-uri, măști și rezultate, astfel încât imaginile originale să rămână nemodificate și

rezultatele să poată fi reproduse.

10. A fost configurat mediul de dezvoltare în Python, utilizând PyCharm ca IDE și biblioteci precum OpenCV, NumPy, Pandas, Matplotlib, Scikit-Image, SciPy, Pillow, OpenPyXL și XlsxWriter.

11. A fost creat fișierul `requirements.txt`, pentru a păstra lista bibliotecilor necesare și pentru a permite refacerea mediului de lucru pe alt calculator.

12. A fost începută implementarea aplicației software, cu o structură modulară orientată pe etape: încărcarea imaginilor, preprocesare, detecția regiunii BGA, detecția pad-urilor, segmentarea voidurilor, calculul parametrilor și generarea rezultatelor.

13. A fost analizată prima imagine de calibrare, `PCBA2\_05.jpg`, deoarece aceasta prezenta clar structura BGA și voidurile din interiorul pad-urilor.

14. În primele teste, algoritmul de detecție a pad-urilor a funcționat parțial, dar au fost observate mai multe probleme: detecții false pe trasee, cercuri plasate doar pe centrul pad-ului și sensibilitate ridicată la structurile circulare din afara BGA-ului.

15. Au fost testate mai multe variante ale algoritmului de detecție a contururilor, urmărind stabilizarea conturului verde pentru fiecare pad înainte de calibrarea detecției voidurilor.

16. A fost introdusă delimitarea automată a regiunii BGA printr-un ROI/pătrat de interes, pentru ca algoritmul să nu mai caute pad-uri în toată imaginea, ci doar în zona relevantă a BGA-ului.

17. A fost observat că poziția BGA-ului diferă de la o imagine la alta, motiv pentru care s-a renunțat la ideea folosirii unor coordonate fixe și s-a urmărit detectarea adaptivă a regiunii BGA.

18. A fost implementată logica de identificare a grilei 16 x 16, corespunzătoare celor 256 de poziții ale pad-urilor BGA.

19. Au fost realizate teste succesive pentru filtrarea candidaților falși, folosind criterii precum aria, circularitatea, raportul de aspect, poziția în grilă și consistența față de vecinii apropiați.

20. A fost introdusă ideea de regularizare geometrică a pozițiilor pad-urilor, astfel încât centrele detectate să respecte mai bine structura regulată a grilei BGA.

21. Au fost întâmpinate dificultăți în imaginile unde BGA-ul era ușor înclinat, decupat diferit sau unde pad-urile apăreau ușor ovalizate. Pentru aceste cazuri, a fost necesară folosirea unui pitch separat pe axele X și Y.

22. Au fost generate imagini intermediare de tip debug pentru verificarea fiecărei etape: candidați inițiali, ROI detectat, candidați respinși, contururi finale și crop-uri pe regiunea BGA.

23. În urma mai multor retușuri, s-a ajuns la rezultate bune pentru familia PCBA2, unde imaginile `PCBA2\_03.jpg`, `PCBA2\_04.jpg`, `PCBA2\_05.jpg` și `PCBA2\_06.jpg` au ajuns la detecții complete sau aproape complete ale grilei BGA.

24. Pentru imaginea `PCBA2\_05.jpg`, considerată imagine principală de calibrare, s-a obținut detecția completă a celor 256 de pad-uri, corespunzătoare grilei 16 x 16.

25. Au fost realizate teste și pe imaginile din familia PCBA1, pentru a verifica dacă algoritmul se generalizează și pe alte imagini, nu doar pe cazul inițial de calibrare.

26. Pentru imaginile `PCBA1\_07.jpg` și `PCBA1\_10.jpg`, algoritmul a ajuns la detecții de 256/256 poziții, iar pentru `PCBA1\_08.jpg` rezultatul a fost aproape complet, necesitând încă retușuri pentru câteva poziții.

27. A fost observat că setul FastScan are contrast și polaritate diferită față de imaginile PCBA1/PCBA2, motiv pentru care acesta ar putea necesita un mod separat de procesare dacă va fi inclus în metodologia finală.

28. A fost începută etapa de detecție a voidurilor în interiorul pad-urilor, după validarea contururilor verzi. Pentru această etapă, fiecare pad detectat este tratat ca o regiune individuală de interes.

29. Au fost realizate primele exemple vizuale de detecție a voidurilor, în care voidurile sunt marcate colorat în interiorul solder balls, pentru a ilustra modul în care va arăta rezultatul final al algoritmului.

30. A fost stabilit setul de parametri care trebuie calculați pentru fiecare solder ball: ID-ul bilei, coordonatele centrului, diametrul, aria bilei, numărul de voiduri, aria totală a voidurilor, cel mai mare void și procentul de voiding.

31. A fost stabilită direcția pentru raportarea finală a rezultatelor, prin generarea de imagini adnotate, fișiere CSV și fișiere Excel cu valorile calculate pentru fiecare pad și pentru întreaga regiune BGA.

32. A fost redactat un rezumat științific al lucrării, incluzând abstract, cuvinte cheie, contextul problemei, metodologia propusă, stadiul actual al dezvoltării și direcțiile următoare.

33. A fost realizată o primă structură a lucrării de disertație, incluzând capitole despre introducere, stadiul actual al cercetării, fundament teoretic, metodologie propusă, implementare software, rezultate experimentale și concluzii.
34. A fost pregătită o listă inițială de referințe bibliografice în format IEEE, pe baza articolelor și documentelor utilizate pentru fundamentarea lucrării.
35. Până la data de 15.06.2026, activitatea principală a fost concentrată pe stabilizarea detecției automate a regiunii BGA și a pad-urilor din grila 16 x 16, deoarece această etapă este esențială pentru ca detecția voidurilor să fie realizată corect.
36. În stadiul actual, algoritmul nu este încă finalizat complet pentru calculul definitiv al procentului de voiding, dar partea de localizare a BGA-ului și de detecție a pad-urilor a fost dezvoltată și validată pe mai multe imagini, reprezentând baza necesară pentru etapa următoare.
37. Următoarele activități vor viza calibrarea segmentării voidurilor, rafinarea măștilor, eliminarea detecțiilor false, calculul procentului de voiding și interpretarea rezultatelor din punct de vedere al calității procesului de lipire.

Data:

Semnătură coordonator:

Semnătură student:

Cuprins

1	INTRODUCERE	5
2	STADIUL ACTUAL AL CERCETĂRII	8
2.1	Metode de inspecție utilizate pentru îmbinările electronice	8
2.2	Inspecția cu raze X și tomografia computerizată	12
2.3	Defecte specifice îmbinărilor BGA	13
2.4	Metode de procesare a imaginilor pentru detecția defectelor	14
3	FUNDAMENT TEORETIC	16
3.1	Caracteristici ale imaginilor X-ray pentru structuri BGA	16
3.2	Preprocesarea imaginilor digitale	16
3.3	Îmbunătățirea contrastului prin CLAHE	17
3.4	Reducerea zgomotului prin filtrare mediană	17
3.5	Detecția formelor circulare prin Hough Circle Transform	17
3.6	Segmentarea imaginilor și metode de thresholding	18
3.7	Calculul procentului de voiding	18
4	METODOLOGIA PROPUȘĂ	20
4.1	Organizarea setului de imagini X-ray	20
4.2	Preprocesarea imaginilor	20
4.3	Detectarea automată a regiunii BGA	21
4.4	Detecția și regularizarea grilei de pad-uri BGA 16 x 16	22
4.5	Extragerea regiunilor individuale pentru fiecare solder ball	22
4.6	Detecția experimentală a voidurilor în interiorul pad-urilor	23
4.7	Filtrarea componentelor false și validarea vizuală	23
4.8	Calculul parametrilor cantitativi	24
4.9	Criterii pentru analiza calitativă a rezultatelor	24
5	IMPLEMENTAREA APLICAȚIEI SOFTWARE	25
5.1	Mediul de dezvoltare	25
5.2	Structura aplicației software	25
5.3	Modulele principale ale aplicației	28
5.4	Fluxul de I/O al datelor	28
5.5	Generarea imaginilor intermediare	29
5.6	Generarea rapoartelor CSV și Excel	29
6	REZULTATE EXPERIMENTALE	31
6.1	Descrierea imaginilor utilizate pentru testare	31
6.2	Rezultate pentru detecția ROI-ului BGA	31
6.3	Rezultate pentru detecția pad-urilor BGA	32
6.4	Validarea grilei 16 x 16	33
6.5	Exemple de detecție a voidurilor medii și mari	33
6.6	Calculul procentului de voiding	34
6.7	Cazuri dificile și limitări observate	35
6.8	Interpretarea rezultatelor din punct de vedere al calității lipirii	38
7	CONCLUZII ȘI DIRECȚII VIITOARE	40

REZUMAT

Lucrarea de față prezintă dezvoltarea unei metode automate pentru detecția și evaluarea voidurilor din structurile BGA, utilizând imagini obținute prin inspecție cu raze X. Tema este relevantă în contextul controlului calității din industria electronică, unde miniaturizarea componentelor și creșterea densității de interconectare fac dificilă verificarea îmbinărilor prin metode optice obișnuite. Deoarece solder balls sunt poziționate sub componentă, defectele interne, precum voidurile, nu pot fi observate direct, fiind necesară utilizarea unor metode de analiză. Scopul lucrării este realizarea unui algoritm clasic și explicabil de procesare a imaginilor, capabil să identifice regiunea BGA, să detecteze pad-urile/solder balls și să analizeze zonele interne ale acestora pentru determinarea voidurilor. Metodologia propusă nu utilizează tehnici de machine learning sau deep learning, ci se bazează pe metode consacrate de procesare digitală a imaginilor. Fluxul de lucru include îmbunătățirea contrastului prin CLAHE, reducerea zgomotului prin filtrare mediană, detecția pad-urilor prin metode geometrice și Hough Circle Transform, segmentarea voidurilor prin thresholding adaptiv, precum și rafinarea rezultatelor prin operații morfologice de opening și closing. Pentru evaluarea cantitativă, voidurile detectate sunt analizate prin Connected Component Analysis. Astfel, pentru fiecare solder ball se determină parametri precum numărul de voiduri, aria totală a acestora, aria celui mai mare void și procentul de voiding raportat la aria bilei analizate. Pe baza acestor valori, rezultatele pot fi interpretate atât individual, la nivel de pad, cât și global, la nivelul întregii regiuni BGA inspectate. Aplicația realizată în Python permite salvarea imaginilor intermediare, a măștilor de segmentare și generarea rapoartelor în format CSV/ Excel. Rezultatele obținute arată că metoda propusă poate oferi o analiză coerentă și reproductibilă a imaginilor X-ray pentru structuri BGA, fiind utilă în identificarea unor posibile neregularități ale procesului de lipire. Prin caracterul său explicabil și prin utilizarea unor algoritmi clasici, soluția poate reprezenta o bază practică pentru evaluarea calității îmbinărilor BGA și pentru îmbunătățirea proceselor de inspecție nedistructivă în domeniul electronicii.

ABSTRACT

This paper presents the development of an automatic method for detecting and evaluating voids in BGA solder joints using X-ray inspection images. The topic is relevant in the context of quality control in the electronics industry, where the continuous miniaturization of components and the increasing density of interconnections make conventional optical inspection insufficient. Since BGA solder balls are placed underneath the component package, internal defects such as voids cannot be directly observed, which makes X-ray inspection, for example, an important solution for evaluating solder joint quality. The main objective of this work is to create a classical and explainable image processing algorithm capable of identifying the BGA region, detecting the solder balls, and analyzing their internal areas in order to determine the presence and size of voids. The proposed approach does not rely on machine learning or deep learning techniques, but instead uses transparent and adjustable image processing methods. The implemented workflow includes contrast enhancement using CLAHE, noise reduction through median filtering, BGA region detection, solder ball localization using geometric constraints and Hough Circle Transform, void segmentation using adaptive thresholding, and mask refinement through morphological opening and closing operations. For the quantitative evaluation, the detected void regions are analyzed using Connected Component Analysis. For each solder ball, several parameters are calculated, including the ball position, diameter, total ball area, number of detected voids, total void area, largest void area, and voiding percentage. These values allow both local evaluation, at solder ball level, and global interpretation, at the level of the inspected BGA structure. The software application was implemented in Python and is able to generate intermediate processing images, segmentation masks, annotated inspection results, and CSV/ Excel reports. The obtained results show that the proposed method can provide a coherent and reproducible analysis of X-ray images containing BGA structures. Due to its explainable character and the use of classical algorithms, the developed solution can support the identification of possible soldering process irregularities and may serve as a practical basis for non-destructive quality assessment in electronic assemblies.

1 INTRODUCERE

Industria electronică modernă se bazează tot mai mult pe ansambluri compacte, performante și capabile să funcționeze în condiții variate de solicitare termică, electrică și mecanică. Pe măsură ce dimensiunile PCB-urilor, iar densitatea componentelor crește, cerințele privind calitatea procesului de fabricație devin tot mai ridicate. În acest context, inspecția calității nu mai reprezintă doar o etapă finală de verificare, ci o parte importantă a procesului de producție, având rolul de a identifica defectele încă din fazele incipiente și de a preveni apariția unor probleme de fiabilitate în exploatare. În cazul ansamblurilor electronice realizate prin tehnologia SMD, defectele pot apărea din cauza variațiilor de proces, a proprietăților materialelor utilizate, a parametrilor de lipire sau a condițiilor de reflow. Printre cele mai importante probleme se numără formarea de goluri în îmbinările de lipire, nealinierea componentelor, defectele de umectare, fisurile sau variațiile geometrice ale îmbinărilor. Aceste defecte pot influența atât performanța electrică a circuitului, cât și rezistența sa pe termen lung la cicluri termice, vibrații sau solicitări mecanice. Din acest motiv, metodele AOI și de analiză a imaginilor au devenit tot mai importante în controlul calității produselor electronice [3], [6], [8], [9]. Cel puțin în ultimii ani, cercetarea din domeniu s-a orientat către metode mai eficiente de inspecție nedistructivă și către integrarea algoritmilor de procesare a imaginilor pentru identificarea automată a defectelor. Studiile recente arată că analiza imaginilor X-ray, completată de tehnici de segmentare, filtrare, clasificare sau inteligență artificială, poate contribui la o evaluare mai rapidă și mai obiectivă a calității îmbinărilor de lipire [2], [5], [6], [8].

Capsulele de tip Ball Grid Array, cunoscute des sub denumirea BGA, sunt utilizate pe scară largă în electronica de astăzi datorită avantajelor pe care le oferă în ceea ce privește densitatea mare de interconectare, dimensiunile compacte și performanța electrică ridicată. Spre deosebire de capsulele clasice cu pini dispuși pe margini, structurile BGA folosesc o matrice de bile de lipire amplasate pe partea inferioară a componentei. Această configurație permite realizarea unui număr mare de conexiuni într-un spațiu redus, ceea ce este esențial pentru circuitele integrate complexe, procesoare, memorii și alte componente utilizate în echipamente electronice avansate. Avantajul miniaturizării vine împreună cu o dificultate majoră: îmbinările de lipire sunt ascunse sub componentă și nu pot fi inspectate direct prin metode optice convenționale. În cazul unei capsule BGA, fiecare bilă de lipire are rolul de a asigura atât contactul electric, cât și fixarea mecanică a componentei pe placa de circuit imprimat. O defecțiune locală, chiar dacă afectează o singură bilă, poate compromite funcționarea întregului ansamblu, mai ales în aplicații în care semnalele sunt rapide, curenții sunt mari sau condițiile de funcționare sunt severe. Fiabilitatea îmbinărilor BGA este influențată de geometria bilelor de lipire, de distribuția tensiunilor termomecanice, de materialul de lipire și de eventualele defecte interne. Studiile dedicate caracterizării geometriei și a voidurilor din ansamblurile BGA arată că analiza cantitativă a acestor structuri este importantă pentru înțelegerea comportării în timp a îmbinărilor și pentru estimarea riscului de defectare [4], [7].

În același timp, cercetările privind inspecția adaptivă a îmbinărilor de lipire indică faptul că metodele automate pot contribui la detectarea mai eficientă a defectelor în componente cu dimensiuni și forme variate [12], [14].

Voidurile reprezintă goluri sau cavități formate în interiorul îmbinărilor de lipire, de regulă în timpul procesului de reflow. Acestea pot apărea din cauza evaporării fluxului, a gazelor captive, a contaminării suprafețelor, a alegerii necorespunzătoare a pastei de lipit, a volumului de pastă depus sau a parametrilor termici utilizați în procesul de lipire. Chiar dacă unele voiduri pot fi tolerate în anumite limite, prezența lor excesivă poate reduce suprafața efectivă de contact, poate modifica distribuția curentului și poate afecta disiparea termică a îmbinării. Influența voidurilor asupra fiabilității depinde de dimensiunea, poziția și distribuția acestora în interiorul bilei de lipire. Un void de dimensiune mică, plasat într-o zonă mai puțin solicitată, poate avea un impact redus, în timp ce un void mare, poziționat într-o zonă critică, poate favoriza apariția fisurilor sau creșterea locală a temperaturii. În aplicații cu solicitări termice repetate, voidurile pot contribui la degradarea progresivă a îmbinării, mai ales atunci când sunt asociate cu evoluția compușilor intermetalici sau cu îmbătrânirea termică a materialului de lipire [7], [10], [11]. Cercetările recente au arătat că volumul și compoziția pastei de lipit pot influența semnificativ formarea voidurilor, iar apariția acestora este strâns legată de controlul procesului tehnologic [1]. De asemenea, analiza apariției voidurilor în îmbinările electronice evidențiază faptul că problema nu este una izolată, ci un fenomen întâlnit frecvent în producția electronică, cu impact direct asupra calității și fiabilității produsului final [3]. Prin urmare, identificarea automată a voidurilor și calcularea procentului ocupat de acestea în solder balls reprezintă o direcție importantă pentru îmbunătățirea controlului calității.

Îmbinările BGA sunt amplasate sub componentă, metodele optice clasice, din păcate, nu pot oferi informații suficiente despre starea internă a bilelor de lipire. În acest caz, inspecția cu raze X devine o metodă, pentru că permite vizualizarea structurilor ascunse fără demontarea sau distrugerea ansamblului. Prin radiografie 2D sau tomografie computerizată 3D, pot fi observate forma bilelor de lipire, poziția acestora, prezența voidurilor, defectele de aliniere sau alte anomalii interne. Inspecția X-ray are avantajul de a fi nedistructivă și de a putea fi integrată în procesele de control al calității pentru componente complexe. Sistemele moderne de radiografie și microCT permit obținerea unor imagini cu rezoluție ridicată, utile pentru analiza detaliată a îmbinărilor și pentru evaluarea defectelor interne [15]. Utilizarea metodelor automate de procesare a imaginilor poate reduce dependența de interpretarea manuală și poate crește repetabilitatea evaluării. Astfel, algoritmi de segmentare, filtrare, detecție a conturilor, analiză a componentelor conectate sau clasificare pot fi utilizați pentru identificarea voidurilor și calcularea raportului dintre suprafața voidurilor și suprafața totală a bilei de lipire [2], [5], [6].

Literatura de specialitate prezintă mai multe abordări pentru detecția voidurilor în imagini X-ray. Unele metode se bazează pe tehnici clasice de procesare a imaginilor, precum praguri adaptive, operații morfologice sau analiza contrastului, în timp ce alte metode utilizează algoritmi de tip K-Means, rețele neuronale sau cadre hibride adaptate pentru inspecții multi-scală [2], [12], [13], [14]. Chiar dacă metodele bazate pe inteligență artificială pot oferi rezultate promițătoare, abordările clasice rămân importante, mai ales atunci când setul de date este limitat, când se dorește o soluție explicabilă sau când obiectivul este dezvoltarea unui algoritm transparent, ușor de justificat într-un context academic și industrial.

Structurile BGA nu sunt relevante doar pentru electronica de consum sau pentru industria auto, ci și pentru domenii în care fiabilitatea este critică, precum electronica biomedicală. Dispozitivele medicale moderne includ frecvent sisteme electronice complexe, module de procesare, senzori, circuite de achiziție, unități de comunicație și platforme integrate pentru analiză de date. În astfel de aplicații, miniaturizarea și densitatea mare de interconectare sunt importante, deoarece echipamentele trebuie să fie compacte, eficiente energetic și capabile să funcționeze stabil pe termen lung. În domeniul biomedical, exemple relevante pot fi întâlnite în sisteme de imagistică medicală, dispozitive de monitorizare, echipamente portabile, platforme de achiziție a semnalelor biomedicale și sisteme bazate pe FPGA sau microcontrolere performante. Un articol publicat în MDPI arată că dispozitivele medicale moderne includ o varietate largă de componente electronice, iar în cazul platformelor de ultrasound sunt utilizate circuite precum FPGA, ADC, amplificatoare cu zgomot redus și drivere de tensiune înaltă, unele dintre acestea având capsule dificil de lipit, inclusiv BGA [16]. În cazul echipamentelor biomedicale, un defect de lipire nu produce doar o problemă tehnică, ci poate afecta siguranța pacientului, acuratețea măsurătorilor sau disponibilitatea unui dispozitiv medical. De aceea, controlul calității pentru structuri de tip BGA devine important în special atunci când componentele sunt utilizate în sisteme de monitorizare, imagistică, diagnostic sau control. Un algoritm capabil să detecteze automat voidurile din solder balls pe baza imaginilor X-ray poate contribui la evaluarea mai rapidă și mai obiectivă a calității ansamblurilor electronice, oferind un suport util pentru decizia de acceptare sau respingere a unei plăci electronice.

Lucrarea se încadrează într-o direcție actuală de cercetare și dezvoltare, aflată la intersecția dintre inspecția nedistructivă, procesarea imaginilor și evaluarea fiabilității îmbinărilor electronice. Scopul urmărit este dezvoltarea unei metode de analiză a imaginilor X-ray pentru identificarea voidurilor în structuri BGA, cu accent pe utilizarea unor tehnici clasice și explicabile de procesare digitală. Prin calcularea procentului de voiduri și evaluarea statistică a rezultatelor, metoda propusă poate oferi o imagine clară asupra calității solder balls și poate constitui o bază pentru îmbunătățirea procesului de inspecție a ansamblurilor electronice [2], [5], [6], [14].

2 STADIUL ACTUAL AL CERCETĂRII

În cadrul capitolului 2 vor fi prezentate principalele metode utilizate pentru inspecția îmbinărilor electronice, cu accent pe tehnicile nedistructive bazate pe raze X. Sunt analizate atât metodele clasice de inspecție, precum radiografia 2D și tomografia computerizată, cât și direcțiile moderne de procesare automată a imaginilor pentru detecția voidurilor (folosite des în fabrici, de exemplu în partea de EOL). Capitolul are rolul de a evidenția contextul științific al lucrării și de a justifica alegerea unei metode explicabile, bazate pe procesare clasică de imagine.

2.1 Metode de inspecție utilizate pentru îmbinările electronice

Inspecția îmbinărilor electronice reprezintă o etapă în procesul de fabricație al ansamblurilor electronice prin intermediul căreia pot fi identificate defecte care nu sunt întotdeauna vizibile sau evidente în timpul funcționării inițiale a produsului și/ sau de ochiul uman. În cazul componentelor montate pe plăci de circuit imprimat, calitatea lipiturilor influențează direct comportarea electrică, stabilitatea mecanică și fiabilitatea pe termen lung a produsului. Din acest motiv, în industrie sunt utilizate mai multe metode de inspecție, de la verificări vizuale și optice, până la tehnici nedistructive cu raze X, tomografie computerizată și metode moderne bazate pe procesare automată de imagine, inteligență artificială sau învățare automată.

O primă categorie de metode este reprezentată de inspecția vizuală și inspecția optică automată. Inspecția vizuală este una dintre cele mai simple metode și presupune verificarea plăcii electronice de către un operator, cu ochiul liber sau cu ajutorul unor instrumente de mărire. Aceasta poate fi utilă pentru identificarea unor defecte evidente, cum ar fi componente lipsă, componente montate greșit, punți de lipire, defecte de polaritate sau urme vizibile de contaminare. Totuși, metoda depinde mult de experiența operatorului și nu este suficientă pentru structuri complexe sau pentru îmbinări ascunse. În producția modernă, inspecția vizuală este înlocuită sau completată de AOI, adică Automated Optical Inspection. Aceasta folosește camere, iluminare controlată și algoritmi de analiză pentru a compara placa verificată cu un model de referință sau cu anumite reguli geometrice. AOI este foarte eficientă pentru componentele la care lipiturile sunt vizibile, de exemplu rezistențe, condensatori, circuite integrate cu pini laterali sau alte componente SMD. Prin AOI se pot detecta defecte precum deplasarea componentelor, lipsa acestora, orientarea greșită, lipituri insuficiente sau excesive și scurtcircuitate între terminale. Totuși, trebuie menționat că această metodă are o limitare importantă în cazul capsulelor de tip BGA, deoarece bilele de lipire se află sub componentă și nu pot fi observate direct. Astfel, chiar dacă o componentă BGA pare corect poziționată la exterior, pot exista defecte în interiorul îmbinărilor, cum ar fi voiduri, lipituri incomplete sau conexiuni slabe.

Din acest motiv, pentru BGA și pentru alte componente cu îmbinări ascunse sunt necesare metode de inspecție care pot analiza structura internă a lipiturii [4], [6].

Pe lângă metodele optice, în fabrici sunt folosite și metode electrice de testare, cum ar fi ICT, flying probe, boundary scan sau testarea funcțională. Aceste metode verifică dacă circuitul se comportă corect din punct de vedere electric. De exemplu, pot fi măsurate continuități, rezistențe, tensiuni sau răspunsuri funcționale ale produsului. În zona de End-of-Line, aceste teste sunt foarte importante, deoarece produsul final este verificat înainte de a fi acceptat sau respins. Un test EOL poate confirma dacă placa electronică funcționează conform specificațiilor, însă nu oferă întotdeauna informații despre cauza fizică a unui defect. De exemplu, o îmbinare cu voiduri poate funcționa corect la început, dar poate deveni problematică după solicitări termice sau mecanice repetate. Din această cauză, testarea electrică este utilă, dar nu este suficientă atunci când se dorește evaluarea calității interne a lipiturilor.

O altă metodă utilizată pentru analiza îmbinărilor este inspecția distructivă, cum ar fi secționarea probei și analiza microscopică. Prin această metodă se poate observa în detaliu structura unei îmbinări de lipire, inclusiv forma acesteia, grosimea straturilor intermetalice sau prezența unor defecte interne. Avantajul este că se pot obține informații foarte precise, însă dezavantajul major este faptul că produsul analizat este distrus. Din acest motiv, inspecția distructivă este folosită mai ales în cercetare, validare de proces, analiză de defect sau control de laborator, dar nu este potrivită pentru verificarea fiecărei plăci într-un flux normal de producție [10], [11].

Pentru îmbinările ascunse, în special pentru BGA, una dintre cele mai importante metode este inspecția nedistructivă cu raze X. Radiografia 2D permite vizualizarea structurilor interne ale îmbinărilor fără demontarea componentelor. În imaginile X-ray, materialele cu densități diferite apar cu niveluri diferite de gri, iar voidurile pot fi observate ca zone cu contrast diferit în interiorul bilelor de lipire. Această metodă este utilă deoarece permite identificarea unor defecte care nu pot fi detectate prin AOI, cum ar fi goluri interne, lipituri incomplete, deplasări ale bilelor sau alte anomalii ale conexiunilor BGA. Studiile recente arată că imaginile X-ray sunt folosite frecvent pentru analiza voidurilor și pentru calcularea raportului dintre aria voidurilor și aria totală a îmbinării [2], [5], [6]. Radiografia 2D are avantajul că este mai rapidă și mai potrivită pentru utilizarea industrială față de metodele volumetrice. De aceea, poate fi integrată mai ușor în fluxuri de inspecție, inclusiv în zona de EOL, unde timpul de verificare este important. Totuși, metoda are și limitări. Deoarece imaginea 2D reprezintă o proiecție a întregii structuri, unele detalii se pot suprapune, iar localizarea exactă a defectului în volum poate fi dificilă. În cazul unor îmbinări foarte complexe, o imagine 2D poate să nu fie suficientă pentru o caracterizare completă. Chiar și așa, pentru multe aplicații industriale, radiografia 2D reprezintă un compromis bun între viteză, cost și cantitatea de informație obținută [2], [9], [13].

O metodă mai avansată este tomografia computerizată cu raze X, cunoscută și ca X-ray CT sau microCT. Aceasta permite reconstruirea tridimensională a obiectului analizat, oferind informații mai detaliate despre geometria îmbinărilor și despre poziția voidurilor în interiorul acestora. În cazul structurilor BGA, CT-ul poate fi folosit pentru caracterizarea cantitativă a

geometriei bilelor de lipire și a defectelor interne, oferind o analiză mai completă decât radiografia 2D [4]. De asemenea, sistemele industriale de microCT sunt utilizate pentru inspecții de înaltă rezoluție, mai ales atunci când este nevoie de o analiză detaliată a defectelor interne [15]. CT-ul necesită un timp mai mare de achiziție și procesare, iar echipamentele sunt mai costisitoare.

Metodele clasice de procesare a imaginilor sunt importante deoarece sunt explicabile și pot fi urmărite pas cu pas. De exemplu, dacă un algoritm folosește filtrare, prag adaptiv și operații morfologice, fiecare etapă poate fi justificată și ajustată în funcție de calitatea imaginii. Acest lucru este util mai ales într-un proiect academic, dar și într-un mediu industrial, unde este important ca rezultatul să nu fie doar corect, ci și ușor de verificat. În literatura de specialitate sunt prezentate mai multe exemple de utilizare a procesării de imagine pentru detecția automată a voidurilor în îmbinări de lipire și în imagini X-ray. Kováč, Girasek și Pietriková au folosit metode de procesare a imaginilor X-ray pentru detecția și evaluarea automată a voidurilor în zona de die attach [5], iar Krammer și colaboratorii au analizat metode de procesare a imaginilor pentru detectarea voidurilor în îmbinările componentelor montate la suprafață [6].

Pe lângă metodele bazate pe praguri și operații morfologice, pot fi utilizate și metode de grupare, cum ar fi K-Means. Într-un astfel de caz, pixelii din imagine sunt împărțiți în mai multe clase în funcție de intensitatea lor, iar clasele rezultate pot fi folosite pentru separarea voidurilor de zona de lipitură. Un exemplu este algoritmul bazat pe K-Means pentru calcularea raportului de voiduri în îmbinările de lipire din imagini X-ray [2]. Avantajul unei astfel de metode este că poate adapta separarea pixelilor în funcție de distribuția intensităților din imagine, fără a folosi întotdeauna un prag fix. Totuși, rezultatul poate depinde de calitatea imaginii, de iluminare, de contrast și de alegerea parametrilor inițiali.

Direcțiile moderne includ și metode bazate pe machine learning, deep learning și inteligență artificială. În acest caz, sistemul nu mai este construit doar prin reguli fixe stabilite de programator, ci învață din exemple, cazuri concrete. Pentru a antrena un model de machine learning sau deep learning, este nevoie de un set de imagini etichetate și nu atât de puține. De exemplu, imaginile pot fi marcate ca fiind acceptabile sau defecte, ori pot conține zone adnotate care indică poziția voidurilor. Pe baza acestor exemple, algoritmul învață diferențele dintre o îmbinare corectă și una cu defecte. În cazul rețelelor neuronale, modelul poate învăța automat caracteristici relevante din imagine, cum ar fi forme, margini, texturi sau variații de contrast. După antrenare, modelul poate fi folosit pentru clasificarea unor imagini noi sau pentru segmentarea automată a defectelor.

În zona de EOL, metodele bazate pe AI pot fi utile deoarece permit verificarea rapidă a unui număr mare de produse. Un sistem de inspecție poate primi imaginea X-ray a unei plăci, poate detecta automat zonele suspecte și poate oferi un rezultat de tip PASS/ FAIL sau un procent de defect. În unele aplicații, sistemul poate evidenția doar zonele care trebuie verificate de operator, reducând timpul de analiză manuală. Integrarea inteligenței artificiale

cu inspecția convențională X-ray a fost analizată în studii recente, unde se urmărește îmbunătățirea detecției voidurilor și reducerea influenței interpretării subiective [8], [9]. Alte cercetări propun cadre adaptive sau hibride pentru inspecția voidurilor în componente precum MOSFET-uri sau chip resistor solder joints, ceea ce arată că domeniul se îndreaptă către soluții mai flexibile, capabile să se adapteze la dimensiuni și forme diferite ale defectelor [12], [14].

Chiar dacă metodele AI și deep learning sunt promițătoare, ele nu înlocuiesc complet metodele clasice. În multe situații, metodele clasice de procesare a imaginilor sunt preferate deoarece sunt mai simple, mai rapide, mai ușor de implementat și mai ușor de explicat. În plus, acestea nu necesită un set mare de date etichetate, ceea ce este un avantaj important atunci când imaginile disponibile sunt limitate. Pentru un algoritm destinat detecției voidurilor în solder balls, o abordare bazată pe îmbunătățirea contrastului, reducerea zgomotului, detecția bilelor, segmentarea voidurilor și calcularea procentului de defect poate reprezenta o soluție potrivită și justificabilă. Această alegere este susținută și de literatura de specialitate, unde metodele clasice și hibride de procesare a imaginilor sunt încă folosite pentru evaluarea defectelor din îmbinări electronice [2], [5], [6], [14].

2.2 Inspecția cu raze X și tomografia computerizată

Principiul metodei se bazează pe trecerea razelor X prin ansamblul electronic și pe formarea unei imagini în funcție de absorbția radiației de către materialele analizate. Materialele mai dense, cum sunt aliajele de lipire, absorb mai multă radiație și apar diferit față de zonele mai puțin dense. Voidurile, fiind goluri sau zone cu densitate redusă, pot fi observate în imagine ca regiuni distincte în interiorul bilelor de lipire. Astfel, printr-o imagine X-ray se pot analiza forma solder balls, poziția acestora, continuitatea îmbinărilor și prezența unor defecte interne [2], [5], [6]. Radiografia 2D este o metodă des folosită în industrie deoarece oferă rezultate rapide și poate fi integrată relativ ușor în fluxurile de inspecție. Aceasta este utilă în special în zona de producție și la verificările de tip End-of-Line, unde timpul de analiză este important. Prin radiografie 2D se poate calcula procentul de voiduri dintr-o îmbinare, se pot identifica zone suspecte și se poate lua o decizie de acceptare sau respingere a produsului. Mai multe lucrări arată că imaginile X-ray pot fi combinate cu algoritmi de procesare a imaginilor pentru segmentarea voidurilor și calcularea raportului dintre aria defectelor și aria totală a îmbinării [2], [5], [6], [9].

Pentru o analiză mai detaliată se poate utiliza tomografia computerizată cu raze X, cunoscută și sub denumirea de X-ray CT sau microCT. Această metodă presupune achiziția mai multor imagini radiografice din unghiuri diferite, urmată de reconstruirea tridimensională a obiectului analizat. În acest mod, pot fi observate forma reală a îmbinărilor, volumul voidurilor, distribuția lor în interiorul solder balls și eventualele variații geometrice ale conexiunilor BGA. Faes și colaboratorii au arătat că tomografia computerizată poate fi utilizată pentru caracterizarea cantitativă și statistică a geometriei îmbinărilor BGA și a voidurilor din acestea [4].

Avantajul principal al tomografiei computerizate este nivelul ridicat de detaliu. Prin CT se pot obține informații volumetrice care nu sunt disponibile într-o simplă radiografie 2D. Acest lucru este important în cercetare, validarea proceselor de fabricație sau analiza unor defecte critice. De asemenea, sistemele moderne de microCT industrial, cum sunt cele prezentate de Waygate Technologies, sunt dezvoltate pentru inspecții de înaltă rezoluție ale componentelor și ansamblurilor electronice [15]. Imaginile folosite în cadrul acestei lucrări, au fost achiziționate cu ajutorul Phoneix Vtomex S240. CT-ul este mai lent, mai costisitor și mai dificil de integrat în inspecția rapidă a fiecărui produs dintr-o linie de fabricație. Dar nu există avantaje fără dezavantaje, și radiografia 2D are anumite limitări. Deoarece imaginea obținută este o proiecție plană a unei structuri tridimensionale, unele detalii se pot suprapune. În cazul unei îmbinări complexe, poate fi dificil de stabilit poziția exactă a unui void în volum sau forma reală a acestuia. De exemplu, două voiduri aflate la adâncimi diferite pot apărea suprapuse în aceeași imagine. Din acest motiv, radiografia 2D este foarte utilă pentru inspecție rapidă, dar nu oferă întotdeauna o caracterizare completă a defectului.

2.3 Defecte specifice îmbinărilor BGA

Îmbinările BGA sunt folosite des în electronică, dar există o problemă - această structură are un dezavantaj: bilele de lipire sunt ascunse sub componentă, ceea ce face dificilă identificarea defectelor prin metode optice obișnuite.

Unul dintre cele mai întâlnite defecte este apariția voidurilor în interiorul bilelor de lipire. Voidurile sunt goluri formate în materialul de lipire, de obicei în timpul procesului de reflow. Acestea pot apărea din cauza evaporării fluxului, a gazelor captive, a contaminării suprafețelor, a volumului de pastă de lipit sau a profilului termic utilizat. Chiar dacă unele voiduri mici pot fi acceptate în anumite limite, voidurile mari sau numeroase pot reduce suprafața efectivă de contact dintre componentă și pad. Acest lucru poate influența atât conducția electrică, cât și disiparea termică a îmbinării [1], [3], [7]. Poziția voidurilor este la fel de importantă ca dimensiunea lor. Un void plasat într-o zonă mai puțin solicitată poate avea un efect redus, în timp ce un void aflat într-o zonă critică poate favoriza apariția unor tensiuni locale sau a unor fisuri. În timp, sub acțiunea ciclurilor termice, vibrațiilor sau îmbătrânirii materialului, aceste defecte pot contribui la degradarea îmbinării. Studiile privind fiabilitatea arată că voidurile pot influența comportarea îmbinărilor de lipire, mai ales în cazul interconectărilor de dimensiuni mici sau supuse unor condiții termice repetate [7], [10], [11].

Un alt defect important este fisurarea îmbinărilor de lipire. Fisurile pot apărea din cauza solicitărilor termomecanice, a diferențelor de dilatare dintre componentă, aliajul de lipire și placa de circuit imprimat sau din cauza îmbătrânirii materialului. În cazul BGA, fisurile sunt periculoase deoarece pot întrerupe parțial sau total conexiunea electrică. Uneori, placa poate funcționa inițial, dar defectul se poate accentua în timp, mai ales în produse expuse la variații de temperatură sau vibrații [7], [10], [11].

Îmbinările BGA pot prezenta și defecte de tip lipitură insuficientă, lipitură rece, nealiniere a bilelor sau contact incomplet între solder ball și pad. De exemplu, dacă procesul de reflow nu este controlat corect, bila de lipire poate să nu se topească uniform sau să nu realizeze o umectare corespunzătoare. În alte cazuri, componenta poate fi ușor deplasată, ceea ce duce la conexiuni neuniforme sau la riscul de scurtcircuit între bile apropiate. Aceste defecte sunt greu de observat din exterior și justifică utilizarea inspecției X-ray în controlul calității [4], [6], [15].

Un defect cunoscut în cazul capsulelor BGA este și fenomenul de tip „head-in-pillow”, în care bila de lipire și pasta de lipit nu se unesc complet în timpul procesului termic. Din exterior, componenta poate părea corect montată, însă contactul electric poate fi instabil. Acest defect este problematic deoarece poate duce la funcționare intermitentă, ceea ce îl face dificil de identificat doar prin testare funcțională [17].

2.4 Metode de procesare a imaginilor pentru detecția defectelor

Procesarea imaginilor practic are rolul cel mai important în inspecție, pentru că permite trecerea de la o simplă imagine X-ray la un rezultat măsurabil. În cazul lucrării de față, interesul principal este identificarea voidurilor din bilele de lipire BGA și calcularea procentului ocupat de acestea. Din punct de vedere practic, un astfel de algoritm trebuie să primească o imagine de intrare, să localizeze solder balls, să separe zonele defecte de zona de lipitură și să ofere la final o evaluare numerică, de exemplu aria voidurilor raportată la aria totală a bilei de lipire. În literatura de specialitate sunt prezentate mai multe abordări pentru detecția voidurilor în imagini X-ray. Unele metode se bazează pe procesare clasică de imagine, folosind filtrare, praguri, operații morfologice și analiză de componente conectate [5], [6]. Alte metode folosesc algoritmi de grupare, cum ar fi K-Means, pentru separarea pixelilor în funcție de nivelul de gri și pentru calcularea raportului de voiduri [2]. În aplicațiile mai recente apar și metode adaptive, hibride sau bazate pe inteligență artificială, dezvoltate pentru inspecția unor defecte la scară diferită, în componente precum MOSFET-uri, chip resistor solder joints sau alte structuri microelectronice [12], [13], [14].

O etapă importantă într-un algoritm de detecție este preprocesarea imaginii. Imaginile X-ray pot conține zgomot, contrast neuniform sau zone cu intensitate apropiată între defect și materialul de lipire. Din acest motiv, înainte de segmentare se aplică de obicei metode de îmbunătățire a contrastului și reducere a zgomotului. O soluție practică este utilizarea CLAHE pentru creșterea contrastului local, urmată de un filtru median pentru reducerea zgomotului de tip impulsiv. Acești pași nu modifică scopul analizei, ci pregătesc imaginea pentru o separare mai clară între solder ball și zonele de void.

După preprocesare, următoarea etapă este detectarea bilelor de lipire. În cazul structurilor BGA, solder balls au de obicei o formă aproximativ circulară și sunt dispuse într-o matrice. Din acest motiv, o metodă potrivită este detecția cercurilor, de exemplu prin Hough Circle Transform. Prin această etapă se obțin coordonatele și raza fiecărei bile, iar analiza poate fi făcută individual pe fiecare regiune de interes. Această abordare este utilă deoarece reduce influența zonelor din afara îmbinării și permite calcularea separată a defectelor pentru fiecare solder ball.

Segmentarea voidurilor este etapa în care zonele suspecte sunt separate de restul materialului de lipire. Pentru această etapă pot fi utilizate praguri globale, praguri adaptive sau metode de grupare. Pragurile adaptive sunt utile atunci când iluminarea sau contrastul nu sunt uniforme pe toată imaginea. În schimb, metodele de tip K-Means pot grupa pixelii în clase diferite pe baza intensității și pot ajuta la separarea voidurilor de zona normală de lipire. Chao și colaboratorii au propus o metodă bazată pe K-Means pentru calcularea raportului de voiduri din imagini X-ray ale îmbinărilor de lipire, ceea ce arată că astfel de metode pot fi aplicate direct în acest tip de analiză [2].

După segmentare, rezultatul brut trebuie de obicei rafinat. În practică, segmentarea poate produce zgomot, zone false sau contururi incomplete. Pentru corectarea acestora se folosesc operații morfologice, cum ar fi deschiderea și închiderea. Deschiderea ajută la eliminarea unor pete mici izolate, iar închiderea poate uni zone apropiate care apar fragmentate. Aceste operații sunt importante deoarece rezultatul final trebuie să fie stabil și să nu depindă prea mult de mici variații de zgomot din imagine. Metode similare de procesare și evaluare automată a voidurilor au fost analizate în lucrări dedicate imaginilor X-ray și îmbinărilor componentelor montate la suprafață [5], [6].

Pentru evaluarea cantitativă se poate utiliza analiza componentelor conectate. După ce voidurile au fost segmentate, fiecare regiune detectată poate fi analizată prin parametri precum arie, poziție, diametru echivalent sau raport față de aria totală a bilei. Criteriul principal urmărit în lucrarea de față este procentul de void, calculat ca raport între aria totală a voidurilor și aria solder ball-ului analizat. Pe baza acestui procent se poate stabili dacă o îmbinare este acceptabilă sau suspectă. Această abordare este potrivită pentru aplicații de tip control al calității, deoarece oferă un rezultat numeric, ușor de interpretat și comparat între mai multe imagini.

În aplicațiile industriale, rezultatul procesării poate fi folosit pentru o decizie de tip PASS/FAIL. De exemplu, dacă procentul de voiduri depășește un prag stabilit, bila sau placa poate fi marcată ca neconformă. Într-un sistem de inspecție de tip End-of-Line, această abordare permite verificarea rapidă a produsului înainte ca acesta să fie livrat sau integrat mai departe. Avantajul este că operatorul nu trebuie să analizeze manual fiecare bilă de lipire, ci poate primi direct zonele suspecte și valorile calculate de algoritm.

Metodele moderne bazate pe machine learning, deep learning sau inteligență artificială pot extinde acest proces. În acest caz, sistemul este antrenat pe imagini etichetate și învață să recunoască automat defectele. De exemplu, rețelele neuronale pot fi folosite pentru detecția rapidă a voidurilor în imagini X-ray 2D, iar metodele AI pot fi integrate cu inspecția convențională pentru a crește viteza și consistența evaluării [8], [9], [13]. Totuși, aceste metode necesită seturi de date bine pregătite, etichetări corecte și validare atentă. În lipsa unui număr mare de imagini reprezentative, o metodă clasică poate fi mai potrivită, deoarece este mai ușor de controlat și de explicat.

Pentru lucrarea de față, abordarea bazată pe procesare clasică de imagine este justificată deoarece urmărește un flux clar și verificabil: îmbunătățirea imaginii, reducerea zgomotului, detecția bilelor BGA, segmentarea voidurilor, rafinarea rezultatului și calcularea procentului de defect. Această metodă nu necesită antrenarea unui model și poate fi adaptată prin ajustarea parametrilor în funcție de calitatea imaginilor X-ray disponibile. În plus, rezultatul final este ușor de interpretat, deoarece fiecare solder ball poate fi asociat cu un procent de void și cu o decizie de acceptare sau respingere [2], [5], [6], [14].

3 FUNDAMENT TEORETIC

Acest capitol prezintă noțiunile teoretice necesare pentru înțelegerea algoritmului propus. Sunt descrise caracteristicile imaginilor X-ray pentru structuri BGA, etapele de preprocesare și metodele utilizate pentru îmbunătățirea contrastului, reducerea zgomotului, detecția formelor circulare și segmentarea voidurilor.

3.1 Caracteristici ale imaginilor X-ray pentru structuri BGA

Imaginile X-ray utilizate pentru analiza structurilor BGA oferă informații despre îmbinările de lipire care nu pot fi observate prin inspecție optică obișnuită. În cazul capsulelor BGA, bilele de lipire sunt poziționate sub componentă, iar accesul vizual direct este imposibil. Prin radiografie, solder balls pot fi analizate în funcție de nivelurile de gri rezultate din absorbția diferită a razelor X de către materialele din ansamblu [2], [4], [15].

Într-o imagine X-ray, zona de lipire apare de obicei ca o regiune compactă, cu intensitate diferită față de substrat sau față de golurile interne. Voidurile pot fi observate ca zone mai deschise sau mai întunecate, în funcție de modul de achiziție și de reprezentarea imaginii. Din punct de vedere al procesării, aceste imagini pot prezenta contrast neuniform, zgomot, suprapuneri de structuri și variații de intensitate între bilele de lipire. De aceea, înainte de detecția efectivă a voidurilor, este necesară aplicarea unor pași de preprocesare și segmentare [5], [6].

Pentru structurile BGA, o caracteristică este forma aproximativ circulară a solder balls. Această proprietate permite folosirea unor metode geometrice pentru localizarea bilelor, după care analiza voidurilor poate fi făcută separat pentru fiecare îmbinare. Astfel, imaginea X-ray nu este analizată doar global, ci pe regiuni de interes, ceea ce permite calcularea unui procent de voiding pentru fiecare solder ball.

3.2 Preprocesarea imaginilor digitale

Preprocesarea reprezintă etapa prin care imaginea X-ray este pregătită pentru analiza propriu-zisă. Scopul acestei etape nu este modificarea informației reale din imagine, ci de fapt îmbunătățirea condițiilor de detecție. În practică, imaginile pot avea zgomot, contrast redus sau variații de iluminare, iar aceste probleme pot duce la rezultate greșite în etapa de segmentare.

În cadrul unui algoritm pentru detecția voidurilor, preprocesarea poate include conversia imaginii în grayscale, normalizarea intensității, îmbunătățirea contrastului și reducerea zgomotului. Aceste operații ajută la evidențierea limitelor dintre solder ball și voiduri, dar și la eliminarea unor detalii irelevante. Lucrările care tratează detecția automată a voidurilor în imagini X-ray folosesc frecvent pași de procesare digitală înainte de evaluarea defectelor, tocmai pentru a obține rezultate mai stabile și mai ușor de interpretat [5], [6].

Pentru lucrarea de față, preprocesarea este importantă deoarece algoritmul se bazează pe metode clasice, nu pe învățare automată. Astfel, calitatea rezultatului depinde mult de cât de bine este pregătită imaginea înainte de detecția cercurilor și segmentarea voidurilor.

3.3 Îmbunătățirea contrastului prin CLAHE

CLAHE, adică Contrast Limited Adaptive Histogram Equalization, este o metodă utilizată pentru îmbunătățirea contrastului local al unei imagini. Spre deosebire de egalizarea clasică a histogramei, CLAHE lucrează pe regiuni mai mici ale imaginii, ceea ce permite evidențierea detaliilor locale fără a modifica excesiv întreaga imagine.

În cazul imaginilor X-ray pentru BGA, CLAHE poate ajuta la evidențierea diferențelor dintre materialul de lipire și zonele de void. Acest lucru este util mai ales atunci când imaginea are contrast redus sau când voidurile nu sunt foarte bine separate vizual de restul solder ball-ului. Prin creșterea contrastului local, etapa de thresholding poate deveni mai stabilă, iar contururile defectelor pot fi mai ușor de identificat.

Totuși, folosirea CLAHE trebuie făcută cu atenție. Dacă parametrii sunt aleși nepotrivit, metoda poate accentua și zgomotul, nu doar defectele reale. Din acest motiv, în fluxul propus, CLAHE este urmată de o etapă de filtrare, pentru a reduce efectele nedorite. Această combinație este potrivită pentru o abordare clasică de procesare a imaginilor, similară ca principiu cu metodele folosite în lucrările dedicate detecției automate a voidurilor [5], [6].

3.4 Reducerea zgomotului prin filtrare mediană

Filtrarea mediană este o metodă simplă și eficientă pentru reducerea zgomotului dintr-o imagine. Aceasta înlocuiește valoarea fiecărui pixel cu mediana valorilor dintr-o vecinătate locală. Avantajul metodei este că poate elimina punctele izolate de zgomot fără a estompa foarte puternic marginile obiectelor.

În imaginile X-ray, zgomotul poate afecta detecția voidurilor, mai ales dacă apar puncte izolate care sunt interpretate greșit ca defecte. Prin aplicarea filtrului median, aceste variații mici pot fi reduse, iar zonele importante din imagine rămân mai clare. Acest lucru ajută atât la detecția solder balls, cât și la segmentarea voidurilor.

Pentru lucrarea de față, filtrarea mediană este aleasă deoarece este ușor de implementat, rapidă și potrivită pentru imagini în care trebuie păstrate contururile. Într-un flux de inspecție, acest pas contribuie la obținerea unui rezultat mai curat înainte de thresholding și analiză morfologică. Metodele de procesare utilizate pentru imaginile X-ray ale îmbinărilor electronice includ frecvent operații de curățare și rafinare a imaginii înainte de evaluarea cantitativă a defectelor [5], [6].

3.5 Detecția formelor circulare prin Hough Circle Transform

Detecția bilelor de lipire este o etapă esențială în analiza structurilor BGA. Deoarece solder balls au, în general, o formă circulară în imaginile X-ray 2D, acestea pot fi detectate folosind Hough Circle Transform. Metoda identifică forme circulare pe baza distribuției marginilor din imagine și oferă, ca rezultat, poziția centrului și raza fiecărui cerc detectat.

În cadrul algoritmului, Hough Circle Transform permite localizarea automată a fiecărei bile de lipire. După detecție, fiecare solder ball poate fi analizat individual prin extragerea unei regiuni de interes. Această abordare este utilă deoarece evită procesarea întregii imagini ca un singur obiect și permite calcularea separată a procentului de voiding pentru fiecare îmbinare.

Din punct de vedere practic, metoda necesită alegerea unor parametri potriviți, cum ar fi raza minimă și maximă a cercurilor, distanța minimă dintre centre și pragurile de detecție. Dacă parametrii nu sunt aleși corect, pot apărea cercuri false sau unele bile pot să nu fie detectate. Totuși, pentru imagini BGA cu bile relativ uniforme și dispuse într-o matrice, această metodă este potrivită și ușor de justificat într-un algoritm clasic de procesare a imaginilor [5], [6].

3.6 Segmentarea imaginilor și metode de thresholding

Segmentarea este etapa prin care imaginea este împărțită în zone relevante pentru analiză. În cazul lucrării de față, scopul segmentării este separarea voidurilor de restul bilei de lipire. După ce solder ball-ul a fost detectat, analiza se face în interiorul regiunii circulare, pentru a evita influența elementelor din afara îmbinării.

O metodă simplă de segmentare este thresholding-ul, adică separarea pixelilor pe baza unui prag de intensitate. Pixelii care trec de acest prag sunt considerați parte dintr-o anumită clasă, de exemplu void sau material de lipire. În cazul imaginilor X-ray, pragul poate fi global sau adaptiv. Pragul global este mai simplu, dar poate avea rezultate slabe dacă imaginea are iluminare neuniformă. Pragul adaptiv este mai flexibil, deoarece calculează pragul local în funcție de zona analizată.

Pe lângă thresholding, pot fi folosite și metode de grupare, cum ar fi K-Means. În acest caz, pixelii sunt împărțiți în clase în funcție de intensitate, iar una dintre clase poate corespunde voidurilor. Chao și colaboratorii au folosit o metodă bazată pe K-Means pentru calcularea raportului de voiduri în îmbinări de lipire analizate din imagini X-ray [2]. Această direcție arată că segmentarea pe baza intensității este potrivită pentru analiza defectelor de tip void. După segmentare, rezultatul poate conține zgomot sau zone false. Din acest motiv, se pot aplica operații morfologice, cum ar fi deschiderea și închiderea, pentru eliminarea regiunilor mici și pentru uniformizarea zonelor detectate. Astfel, imaginea binară finală devine mai potrivită pentru calculul procentului de voiding [5], [6], [14].

3.7 Calculul procentului de voiding

Calculul procentului de voiding reprezintă etapa finală a metodei de analiză. După detectarea solder ball-ului și segmentarea voidurilor, se calculează raportul dintre aria totală a voidurilor și aria totală a bilei de lipire analizate. Rezultatul se exprimă procentual și poate fi folosit ca indicator al calității îmbinării.

Formula generală poate fi exprimată astfel:

$$Voiding [\%] = \frac{A_{voiduri}}{A_{solder}} \cdot 100 \quad (1)$$

În formula (1), A_{voiduri} reprezintă aria totală a voidurilor și A_{solder} aria totală a solder ball-ului. În această formulă, aria solder ball-ului poate fi determinată pe baza regiunii circulare detectate, iar aria voidurilor este calculată prin numărarea pixelilor segmentați ca defecte. Prin această abordare, fiecare bilă de lipire primește o valoare numerică, ceea ce permite compararea între îmbinări și identificarea zonelor cu probleme.

Acest tip de evaluare este utilizat în mai multe lucrări dedicate analizei voidurilor din imagini X-ray. De exemplu, metodele bazate pe procesare de imagine sau K-Means urmăresc calcularea raportului de voiduri pentru a obține o apreciere cantitativă a defectului [2], [5], [6]. În aplicații industriale, un astfel de procent poate fi comparat cu un prag de acceptare, iar rezultatul poate fi transformat într-o decizie de tip PASS/FAIL.

Pentru lucrarea de față, calculul procentului de voiding este important deoarece transformă imaginea X-ray într-un rezultat obiectiv. În loc ca evaluarea să fie doar vizuală, algoritmul oferă o valoare numerică pentru fiecare solder ball. Astfel, metoda propusă poate fi folosită pentru analiza calității îmbinărilor BGA și pentru evidențierea bilelor care prezintă un nivel ridicat de voiduri [2], [6], [14].

4 METODOLOGIA PROPUȘĂ

În acest capitol este descrisă metodologia dezvoltată pentru detecția și evaluarea voidurilor din în contextul BGA. Procesul pornește de la organizarea setului de imagini X-ray și continuă cu preprocesarea, identificarea regiunii BGA, regularizarea grilei de pad-uri și extragerea regiunilor individuale pentru fiecare solder ball. Ulterior, voidurile sunt segmentate și filtrate, iar rezultatele sunt transformate în parametri cantitativi utilizați pentru aprecierea calității îmbinărilor.

4.1 Organizarea setului de imagini X-ray

Organizarea setului de imagini X-ray se referă la pregătirea imaginilor pentru a fi procesate de către algoritmul din Python. În general este recomandată o bună organizare a proiectului după ce a fost creat/ importat de exemplu în IDE (în acest caz, PyCharm). Pentru acest algoritm, numărul de imagini este unul limitat, impactul este asupra două clase de PCBA-uri, anume PCBA1 și PCBA2. În folderul de PCBA1 avem 3 imagini în urma procesului X-ray ar în PCBA2 5 imagini. Avem și un folder FastScan cu imagini care au fost obținute în regim de tip FastScan, adică într-un mod de achiziție rapidă, adecvat pentru inspecție vizuală și evaluare preliminară a defectelor. Denumirea aceasta de FastScan indică faptul că prioritatea achiziției este reducerea timpului de scanare, cu un compromis posibil asupra nivelului de zgomot, contrastului și artefactelor față de o scanare CT completă de înaltă rezoluție. Aceste imagini pentru PCBA1 și PCBA2 reprezintă variantele brute, neprocesate - efectiv imaginile rezultate în urma scanării CT/ scanare prin raze X. Organizarea generală este împărțită în 5 foldere, anume: Masks, Processed, Raw, Results, ROI. Folderul de Processed, reprezintă imaginile prelucrate și adnotate, ROI regiunile de interes extrase, Masks măștile binare rezultate în urma segmentării, iar Results rapoartele numerice și fișierele finale utilizate pentru interpretarea rezultatelor. Toate acestea fac parte din folderul de imagini numit Images_BGA.

4.2 Preprocesarea imaginilor

Preprocesarea imaginilor reprezintă prima etapă aplicată asupra imaginilor X-ray înainte de detecția propriu-zisă a regiunii BGA și a voidurilor. Scopul acestei etape este de a îmbunătăți calitatea imaginii de intrare, astfel încât elementele relevante, precum solder balls, pad-urile și eventualele voiduri, să poată fi identificate mai stabil în etapele următoare. Imaginile X-ray pot conține variații de iluminare, contrast redus, zgomot local sau artefacte rezultate în urma procesului de achiziție. Din acest motiv, imaginea brută nu este utilizată direct pentru segmentare, deoarece diferențele dintre structurile metalice, fundal și voiduri pot fi greu de separat. În cadrul metodologiei propuse, preprocesarea se realizează prin două operații principale: îmbunătățirea contrastului local prin CLAHE și reducerea zgomotului prin filtrare mediană.

Prima operație aplicată este CLAHE, adică Contrast Limited Adaptive Histogram Equalization. Această metodă îmbunătățește contrastul local al imaginii, fără a amplifica excesiv zonele foarte luminoase sau foarte întunecate. Spre deosebire de o egalizare globală a histogrammei, CLAHE împarte imaginea în regiuni mai mici și ajustează contrastul local, ceea ce este util pentru imaginile X-ray în care intensitatea nu este uniformă pe toată suprafața. În implementarea aplicației, metoda este aplicată cu un clipLimit de 2.0 și o dimensiune a grilei de 8 x 8, valori alese pentru a evidenția structurile BGA fără a introduce artefacte vizuale puternice.

După îmbunătățirea contrastului, imaginea este filtrată cu un filtru median. Această operație are rolul de a reduce zgomotul local, păstrând în același timp marginile importante ale structurilor circulare. Filtrarea mediană este potrivită în acest context deoarece nu estompează la fel de agresiv contururile precum alte filtre de netezire, iar marginile solder balls și ale voidurilor trebuie păstrate cât mai clar pentru detecția ulterioară. În aplicația dezvoltată, filtrul median este aplicat cu un kernel de dimensiune 5.

Rezultatul acestei etape este format din două imagini intermediare: imaginea cu contrast îmbunătățit prin CLAHE și imaginea finală preprocesată, obținută după aplicarea filtrului median. Imaginea preprocesată este utilizată mai departe pentru identificarea regiunii BGA, detecția pad-urilor și segmentarea voidurilor. Astfel, preprocesarea contribuie la stabilizarea întregului algoritm, reducând influența zgomotului și a variațiilor de contrast asupra rezultatelor finale.

4.3 Detectarea automată a regiunii BGA

Detectarea automată a regiunii BGA are rolul de a separa zona relevantă a imaginii de restul structurilor existente pe placa electronică. În imaginile X-ray analizate nu apar doar pad-urile BGA, ci și trasee, vias, componente laterale și alte zone metalice care pot influența negativ detecția. Din acest motiv, utilizarea unor coordonate fixe nu reprezintă o soluție suficient de robustă, deoarece poziția BGA-ului poate varia de la o imagine la alta.

Metodologia propusă pornește de la ideea că structura BGA are o organizare regulată, sub forma unei matrice de pad-uri. Astfel, regiunea BGA este estimată pe baza candidaților care au caracteristici compatibile cu solder balls și care formează o distribuție densă și ordonată. În această etapă pot fi utilizate metode precum detecția formelor circulare, analiza componentelor compacte și verificarea distanțelor dintre vecini. Candidații izolați sau cei care apar pe trasee sunt eliminați, deoarece nu fac parte din structura repetitivă a BGA-ului. Această abordare este justificată și de literatura de specialitate, unde analiza automată a voidurilor începe, de regulă, prin identificarea regiunii de interes înainte de segmentarea defectelor. Separarea zonei analizate este importantă deoarece voidurile trebuie evaluate doar în interiorul îmbinărilor de lipire, nu în fundalul imaginii sau pe traseele plăcii [5], [6]. Prin urmare, detectarea regiunii BGA reprezintă o etapă de stabilizare a algoritmului și reduce riscul ca elemente externe să fie interpretate greșit ca pad-uri sau voiduri.

4.4 Detecția și regularizarea grilei de pad-uri BGA 16 x 16

După identificarea regiunii BGA, următoarea etapă constă în detectarea pad-urilor individuale și regularizarea acestora într-o grilă de tip 16 x 16. Pentru cazul analizat, această organizare corespunde unui număr maxim de 256 de poziții posibile. În practică, detecția directă a tuturor pad-urilor poate fi afectată de contrast, zgomot, suprapuneri de trasee sau deformări de perspectivă ale imaginii X-ray.

Din acest motiv, algoritmul nu se bazează doar pe detecția individuală a cercurilor, ci verifică și coerența geometrică a întregii grile. Pad-urile detectate sunt analizate în funcție de poziție, distanță față de vecini, dimensiune și apartenență la structura regulată a BGA-ului. În cazul în care anumite poziții sunt slab evidențiate, acestea pot fi tratate ca poziții estimate sau recuperate doar dacă există suficientă evidență locală în imagine. Această idee este utilă mai ales în zonele în care Hough Circle Transform sau analiza conturilor pot detecta incomplet limita reală a pad-ului.

Regularizarea grilei are și rolul de a evita supradetecția. În imaginile X-ray, anumite trasee sau vias pot avea forme aproximativ circulare și pot fi confundate cu pad-uri. Prin raportarea fiecărui candidat la grila 16 x 16, aceste detecții false pot fi eliminate mai ușor. Metode similare, bazate pe caracteristici geometrice, distribuție regulată și filtrarea componentelor, sunt discutate în lucrările dedicate inspecției automate a voidurilor în BGA și în alte îmbinări electronice [14].

4.5 Extragerea regiunilor individuale pentru fiecare solder ball

După validarea pad-urilor, fiecare solder ball este analizat separat prin extragerea unei regiuni individuale de interes. Această regiune este, în general, o zonă pătrată sau circulară centrată pe pad-ul detectat, suficient de mare pentru a include întreaga bilă de lipire, dar suficient de restrânsă pentru a exclude cât mai mult din fundalul înconjurător.

Extragerea individuală este importantă deoarece segmentarea voidurilor trebuie realizată local, nu pe întreaga imagine. Într-o imagine X-ray completă, intensitatea pixelilor poate varia semnificativ de la o zonă la alta, iar un prag global poate produce rezultate instabile. Prin analizarea fiecărei bile separat, algoritmul poate compara voidurile cu fundalul local al acelei îmbinări, ceea ce crește șansa unei segmentări mai corecte.

Această etapă respectă principiul conform căruia voidurile trebuie căutate doar în interiorul zonei de lipire. În cazul BGA, geometria aproximativ circulară a solder balls permite definirea unei măști circulare de analiză, astfel încât zonele din afara bilei să nu fie incluse în calculul final. În literatura de specialitate, această separare a regiunii de interes este considerată o etapă esențială pentru măsurarea corectă a voidurilor și pentru calculul procentului de voiding [2], [6].

4.6 Detecția experimentală a voidurilor în interiorul pad-urilor

Detecția voidurilor se realizează în interiorul fiecărei regiuni individuale asociate unui solder ball. În imaginile X-ray, voidurile apar de regulă ca zone mai luminoase în interiorul lipiturii, deoarece reprezintă goluri sau regiuni cu material lipsă, care atenuează diferit radiația X față de materialul metalic din jur. Totuși, această diferență de intensitate nu este întotdeauna uniformă, motiv pentru care detecția trebuie tratată adaptiv.

În metodologia propusă, segmentarea voidurilor este abordată experimental, prin combinarea unor criterii de luminozitate locală, contrast față de fundalul apropiat și limitare la interiorul solder ball-ului. În locul unui singur prag fix, se pot utiliza metode de thresholding adaptiv, praguri bazate pe distribuția intensităților din ROI și operații morfologice pentru curățarea măștii binare. Această abordare este potrivită pentru imagini X-ray în care contrastul poate diferi între zonele centrale și marginile BGA-ului.

Lucrările existente susțin utilizarea unor metode clasice precum thresholding global sau adaptiv, blob detection, Canny edge detection, procesare morfologică și analiză pe componente conectate pentru detecția voidurilor [6]. De asemenea, studiile privind calculul void ratio evidențiază o structură generală formată din preprocesare, procesare morfologică, extragerea voidurilor și calculul raportului de voiding [2]. În cazul de față, metodele sunt adaptate pentru structuri BGA și pentru un flux explicabil, fără utilizarea unor modele de tip machine learning sau deep learning.

4.7 Filtrarea componentelor false și validarea vizuală

După segmentarea inițială, masca binară poate conține nu doar voiduri reale, ci și componente false. Acestea pot apărea din cauza zgomotului, a marginilor solder ball-ului, a reflexiilor din imagine, a traseelor suprapuse sau a variațiilor locale de contrast. Din acest motiv, o etapă separată de filtrare este necesară înainte de calculul final al parametrilor.

Filtrarea componentelor se bazează pe proprietăți geometrice și morfologice. Sunt analizate aria componentei, raportul dintre lățime și înălțime, circularitatea, gradul de alungire și poziția față de marginea bilei. Componentele foarte mici sunt considerate zgomot, iar cele foarte alungite pot indica margini, arce sau trasee, nu voiduri reale. De asemenea, componentele aflate predominant pe marginea solder ball-ului sunt tratate cu atenție, deoarece pot proveni din conturul bilei și nu dintr-un defect intern.

Validarea vizuală rămâne importantă, mai ales deoarece algoritmul este unul clasic și nu învață automat din exemple adnotate. Din acest motiv, aplicația generează imagini intermediare, cum ar fi regiunea BGA detectată, conturile pad-urilor, măștile de void și imaginea finală adnotată. Aceste rezultate permit verificarea rapidă a cazurilor în care algoritmul a detectat prea multe sau prea puține componente. În etapa de dezvoltare, această validare este esențială pentru ajustarea parametrilor și pentru identificarea cazurilor dificile.

4.8 Calculul parametrilor cantitativi

După obținerea măștii finale pentru fiecare solder ball, voidurile acceptate sunt analizate prin connected component analysis. Fiecare componentă conectată din mască este interpretată ca un posibil void, iar pentru aceasta se determină aria în pixeli. Pe baza acestor informații se calculează numărul de voiduri, aria totală a voidurilor și aria celui mai mare void identificat.

Parametrul principal utilizat în evaluare este procentul de voiding. Acesta se calculează ca raport între aria totală a voidurilor detectate și aria solder ball-ului analizat, exprimat procentual. Astfel, pentru fiecare bilă BGA se poate obține o valoare numerică ce descrie severitatea voidurilor din acea îmbinare. Pe lângă procentul total de voiding, poate fi utilă și analiza celui mai mare void individual, deoarece un singur void de dimensiune mare poate fi mai problematic decât mai multe voiduri mici distribuite uniform.

Rezultatele cantitative pot fi salvate sub formă de rapoarte CSV sau Excel, conținând pentru fiecare solder ball identificatorul, coordonatele centrului, diametrul, aria estimată, numărul de voiduri, aria totală a voidurilor, aria celui mai mare void și procentul de voiding. Această formă de raportare permite compararea imaginilor între ele și oferă o bază obiectivă pentru interpretarea calității procesului de lipire. Importanța unei caracterizări cantitative și statistice a voidurilor în BGA este subliniată și în studiile care analizează distribuția voidurilor și geometria îmbinărilor pe seturi mai mari de date [4].

4.9 Criterii pentru analiza calitativă a rezultatelor

Analiza calitativă are rolul de a transforma valorile numerice obținute într-o interpretare mai ușor de utilizat. În acest scop, fiecare solder ball poate fi încadrat într-o categorie de tip PASS, REVIEW sau FAIL, în funcție de procentul de voiding și de dimensiunea celui mai mare void. Pragurile utilizate trebuie să fie configurabile, deoarece ele pot depinde de standardul aplicat, de cerințele companiei, de tipul componentei și de criticitatea aplicației. O abordare practică este utilizarea unui prag de avertizare pentru cazurile care necesită verificare suplimentară și a unui prag de respingere pentru cazurile în care voiding-ul depășește o limită considerată neacceptabilă. În literatura de specialitate apar frecvent valori apropiate de 20-25% pentru acceptabilitatea voidurilor în solder balls, însă aceste limite trebuie interpretate în contextul aplicației și al standardului folosit [1], [2], [3]. Din acest motiv, în lucrare aceste praguri sunt tratate ca parametri ajustabili, nu ca valori absolute. La nivelul întregii imagini, verdictul calitativ poate fi stabilit în funcție de cea mai critică bilă detectată. Dacă toate îmbinările se află sub pragul de avertizare, imaginea poate fi considerată PASS. Dacă una sau mai multe bile depășesc pragul de avertizare, dar nu ating pragul de respingere, rezultatul poate fi încadrat ca REVIEW. Dacă cel puțin o bilă depășește pragul de respingere, imaginea poate fi clasificată ca FAIL. Această interpretare nu înlocuiește o validare industrială completă, dar oferă un mod clar și repetabil de evaluare preliminară a calității îmbinărilor BGA.

5 IMPLEMENTAREA APLICAȚIEI SOFTWARE

Acest capitol prezintă modul în care metodologia propusă a fost transpusă într-o aplicație software implementată în Python. Sunt descrise mediul de dezvoltare, bibliotecile folosite, structura aplicației, modulele principale și fluxul de prelucrare a datelor, de la imaginea brută până la rezultatele finale. De asemenea, sunt prezentate imaginile intermediare generate pentru validare vizuală și rapoartele CSV/ Excel utilizate pentru analiza voidurilor detectate.

5.1 Mediul de dezvoltare

Algoritmul a fost implementat în limbajul Python, acesta fiind deja cunoscut că oferă un ecosistem potrivit pentru prelucrarea imaginilor, analiza numerică și generarea de rapoarte. Dezvoltarea a fost realizată într-un proiect local organizat pe foldere, astfel încât imaginile de intrare, imaginile intermediare și rezultatele finale să fie separate clar. Această organizare a fost utilă mai ales în etapa de testare, deoarece algoritmul a fost ajustat treptat pe mai multe imagini X-ray, iar fiecare rulare a trebuit să poată fi verificată vizual. Pentru procesarea imaginilor au fost utilizate în principal biblioteci specifice lucrului cu matrice și imagini digitale. Biblioteca OpenCV a fost folosită pentru încărcarea imaginilor grayscale, aplicarea filtrelor, detecția formelor, operații morfologice, segmentare și salvarea imaginilor rezultate. NumPy a fost utilizat pentru operații numerice asupra matricelor de pixeli, iar Pandas a fost folosit pentru organizarea rezultatelor sub formă tabelară. Pentru exportul rapoartelor în format Excel a fost utilizat un motor dedicat de scriere a fișierelor .xlsx. Mediul de lucru a fost gândit astfel încât aplicația să poată fi rulată atât pe o singură imagine, cât și pe un folder care conține mai multe imagini X-ray. Din acest motiv, programul principal permite introducerea căii către o imagine individuală sau către un director de imagini. Această abordare a fost utilă în testare, deoarece unele imagini au fost folosite pentru calibrarea detecției pad-urilor, iar altele pentru verificarea comportamentului algoritmului în cazuri mai dificile.

5.2 Structura aplicației software

Conform figurii 1, algoritmul pornește de la imaginea X-ray brută, care conține zona BGA împreună cu alte structuri ale plăcii, precum trasee PCB, vias și elemente metalice. În prima etapă, imaginea este încărcată în format grayscale, deoarece informația utilă pentru analiză este dată de nivelurile de intensitate ale pixelilor. Ulterior, se aplică etapa de preprocesare, formată din îmbunătățirea contrastului local prin CLAHE și reducerea zgomotului prin filtru median. Aceste operații au rolul de a evidenția mai bine solder balls și eventualele voiduri, păstrând în același timp marginile importante ale pad-urilor. După preprocesare, algoritmul trece la detectarea regiunii BGA. Pentru aceasta sunt căutate forme circulare compatibile cu pad-urile sau solder balls, utilizând Hough Circle Transform. Pad-urile detectate sunt apoi regularizate într-o grilă BGA de tip 16 x 16, astfel încât detecțiile false să fie eliminate, iar structura regulată a capsulei să fie păstrată. În continuare, pentru fiecare solder ball este extrasă o regiune individuală de interes, astfel încât analiza voidurilor să fie realizată local, doar în interiorul fiecărui pad.

În etapa de segmentare, în fiecare ROI se aplică thresholding adaptiv pentru identificarea zonelor care pot reprezenta voiduri. Deoarece imaginile X-ray pot avea variații de intensitate de la o zonă la alta, această abordare locală este mai potrivită decât utilizarea unui prag global fix. Masca binară obținută este apoi rafinată prin operații morfologice de opening și closing. Opening-ul ajută la eliminarea punctelor mici de zgomot, iar closing-ul contribuie la stabilizarea formelor detectate.

După rafinarea măștii, fiecare regiune detectată este analizată prin Connected Component Analysis. În această etapă se determină numărul de voiduri, aria totală a acestora și aria celui mai mare void. Pe baza acestor valori se calculează procentul de voiding pentru fiecare solder ball, raportând aria totală a voidurilor la aria pad-ului analizat. Procentul obținut este comparat cu pragurile stabilite, iar rezultatul este încadrat într-una dintre categoriile PASS, REVIEW sau FAIL. Astfel, PASS indică o îmbinare acceptabilă, REVIEW semnalează necesitatea unei verificări suplimentare, iar FAIL indică o posibilă neconformitate.

La finalul fluxului, aplicația generează rapoarte CSV și Excel, care conțin rezultatele numerice ale analizei. În paralel, sunt salvate imaginile procesate, măștile binare, regiunile ROI decupate și rezultatele finale, pentru ca evaluarea să poată fi verificată atât vizual, cât și cantitativ.

Din punct de vedere software, aplicația urmărește un flux clar: imaginea brută este citită din folderul de intrare, este preprocesată, se detectează zona BGA și grila de pad-uri, apoi fiecare solder ball este analizat individual. Pentru fiecare pad sunt extrase voidurile, sunt calculate metricile cantitative, iar rezultatele sunt centralizate în fișiere CSV și Excel. Astfel, structura aplicației susține atât analiza automată, cât și verificarea manuală a rezultatelor.

Un avantaj al acestei abordări e faptul că aplicația rămâne flexibilă. Dacă în etapele viitoare se dorește schimbarea metodei de segmentare, ajustarea pragurilor sau introducerea unei alte metode de validare, modificările pot fi realizate local, în modulul corespunzător. În acest fel, aplicația nu este construită ca un bloc rigid, ci ca un flux de procesare ușor de urmărit și de extins.




Figura 1. Diagrama fluxului de date pentru algoritmul folosit

5.3 Modulele principale ale aplicației

Modulul principal al aplicației este `main.py`, care coordonează întregul flux de procesare. Acesta preia imaginea sau folderul de imagini, creează directoarele de ieșire, apelează pe rând modulele de procesare și salvează rezultatele. Practic, acest fișier funcționează ca un punct central al aplicației, fără să conțină toate detaliile algoritmice ale fiecărei etape.

Modulul `image_loader.py` se ocupă de încărcarea imaginilor în format grayscale și de identificarea fișierelor imagine acceptate dintr-un folder. Această etapă este importantă deoarece imaginile X-ray sunt analizate ca imagini monocrome, unde informația relevantă este reprezentată prin niveluri de intensitate.

Modulul `preprocessing.py` aplică operațiile inițiale de îmbunătățire a imaginii. În aplicație se utilizează CLAHE pentru creșterea contrastului local și un filtru median pentru reducerea zgomotului. Rezultatul acestei etape este o imagine mai stabilă pentru detecția pad-urilor și pentru segmentarea ulterioară.

Modulul `ball_detection.py` e responsabil pentru identificarea regiunii BGA și a pad-urilor sau solder balls. Acesta include detecție bazată pe forme circulare, candidați de tip blob, verificări geometrice și regularizarea grilei 16 x 16. În timpul dezvoltării, această parte a fost una dintre cele mai sensibile, deoarece unele trasee sau vias puteau fi confundate cu pad-uri. Din acest motiv, modulul include și mecanisme de filtrare a candidaților și de validare a pozițiilor în raport cu grila.

Modulul `void_segmentation.py` realizează segmentarea voidurilor în interiorul fiecărui solder ball. Segmentarea este aplicată local, pe fiecare ROI extras, nu pe imaginea completă. În forma actuală, metoda urmărește zonele luminoase compacte din interiorul bilei de lipire, folosind contrastul local față de fundal și evitând pe cât posibil marginea solder ball-ului, unde pot apărea artefacte.

Modulul `metrics.py` are rolul de a filtra componentele segmentate și de a calcula parametrii numerici. Acesta verifică aria, forma și poziția componentelor, pentru a elimina punctele mici, arcele de margine sau formele alungite care nu corespund unor voiduri reale. După filtrare, modulul calculează numărul de voiduri, aria totală a voidurilor și aria celui mai mare void.

Modulul `visualization.py` generează imaginile intermediare și finale utilizate pentru validare vizuală. Acesta desenează regiunea BGA detectată, contururile pad-urilor, imaginile adnotate și previzualizarea măștilor de void. Modulul `reporting.py` construiește rapoartele finale în format CSV și Excel, astfel încât rezultatele să poată fi analizate numeric.

5.4 Fluxul de I/O al datelor

Fluxul de intrare/ieșire al aplicației începe cu imaginea X-ray originală, aflată în folderul Raw, cu imagini brute. Utilizatorul poate rula aplicația pe o singură imagine sau pe un director care conține mai multe imagini. În cazul în care nu este introdusă direct o cale prin argumente, programul poate solicita manual calea către imagine sau folder. Această variantă a fost utilă pentru testare, deoarece permite rularea rapidă fără modificarea codului. După încărcarea imaginii, aceasta este convertită sau citită direct ca imagine grayscale. Apoi sunt create automat directoarele de ieșire, astfel încât fiecare rezultat să fie salvat într-

un loc corespunzător. Imaginea preprocesată este salvată în Processed, regiunile individuale ale pad-urilor sunt salvate în `ROI`, iar măștile binare ale voidurilor sunt salvate în Masks. Rapoartele tabelare și sumarul final sunt salvate în Results.

Fluxul general poate fi descris astfel: imagine brută, preprocesare, detecție ROI BGA, detecție și regularizare pad-uri, extragere ROI pentru fiecare solder ball, segmentare voiduri, filtrare componente, calcul metrici, generare imagini și rapoarte. Această ordine permite urmărirea clară a fiecărei etape și face mai ușoară identificarea problemelor apărute în timpul testării.

Un avantaj al acestei structuri este faptul că rezultatele intermediare nu sunt pierdute. Dacă o detecție finală nu este corectă, se poate verifica separat dacă problema a apărut la preprocesare, la localizarea BGA-ului, la conturarea pad-urilor sau la segmentarea voidurilor.

5.5 Generarea imaginilor intermediare

Generarea imaginilor intermediare a fost introdusă pentru validarea vizuală a algoritmului. În cazul inspecției X-ray, valorile numerice nu sunt suficiente dacă nu se poate verifica și imaginea pe baza căreia au fost calculate. Din acest motiv, aplicația salvează mai multe tipuri de imagini rezultate după fiecare etapă importantă.

Prima categorie de imagini intermediare este formată din imaginile obținute după preprocesare. Acestea permit observarea efectului produs de CLAHE și de filtrul median asupra imaginii brute. Dacă imaginea devine prea contrastată sau dacă zgomotul este amplificat, aceste rezultate pot fi observate înainte ca problema să afecteze segmentarea.

A doua categorie este reprezentată de imaginile de diagnostic pentru regiunea BGA. Acestea includ candidații inițiali detectați, dreptunghiul sau pătratul asociat ROI-ului BGA și conturile pad-urilor finale. În timpul dezvoltării, aceste imagini au fost foarte importante, deoarece problema principală nu a fost doar detecția voidurilor, ci și stabilizarea conturilor pad-urilor, mai ales spre marginile BGA-ului.

A treia categorie este formată din ROI-urile individuale pentru fiecare solder ball. Aceste imagini ajută la verificarea modului în care fiecare pad a fost decupat și analizat separat. Dacă ROI-ul nu este centrat corect sau dacă include prea mult fundal, rezultatul segmentării poate fi afectat.

Ultima categorie este reprezentată de măștile de void și imaginile finale adnotate. Măștile arată exact ce zone au fost considerate voiduri, iar imaginile finale permit observarea rezultatului peste imaginea originală. Aceste rezultate sunt utile atât pentru analiza calitativă, cât și pentru prezentarea vizuală a funcționării aplicației în lucrare.

5.6 Generarea rapoartelor CSV și Excel

După finalizarea procesării imaginii, aplicația generează rapoarte numerice pentru analiza rezultatelor. Pentru fiecare solder ball detectat sunt salvate informații precum identificatorul bilei, coordonatele centrului, diametrul estimat, aria bilei, numărul de voiduri, aria totală a voidurilor, aria celui mai mare void, procentul de voiding și verdictul calitativ.

Raportul CSV este bun pentru verificări rapide, prelucrare ulterioară sau import în alte aplicații. Formatul Excel este mai potrivit pentru analiză manuală, deoarece permite vizualizarea tabelară mai clară a rezultatelor. În fișierul Excel sunt incluse atât datele detaliate pentru fiecare solder ball, cât și un sumar al imaginii analizate.

Sumarul include numărul total de bile analizate, procentul mediu de voiding, procentul maxim de voiding și numărul de bile care depășesc pragul de avertizare. În aplicație, clasificarea calitativă este realizată pe baza unor praguri configurabile. Astfel, o bilă poate fi încadrată ca PASS, REVIEW sau FAIL, în funcție de procentul total de voiding și de dimensiunea celui mai mare void.

6 REZULTATE EXPERIMENTALE

În capitolul 6 sunt prezentate rezultatele obținute prin aplicarea algoritmului asupra imaginilor X-ray din setul de test. Sunt analizate separat detecția regiunii BGA, identificarea pad-urilor, validarea grilei 16 x 16 și detecția voidurilor în interiorul solder balls. Rezultatele sunt interpretate atât vizual, prin imaginile adnotate, cât și cantitativ, prin calculul procentului de voiding și al parametrilor asociați fiecărei îmbinări.

6.1 Descrierea imaginilor utilizate pentru testare

Pentru testarea algoritmului au fost utilizate imagini X-ray ale unor ansambluri PCB care conțin structuri BGA. Imaginile prezintă atât zona de interes, formată din pad-uri și solder balls, cât și elemente externe precum trasee, vias, componente laterale și zone metalice cu intensități diferite. Din acest motiv, setul de test este util pentru verificarea comportamentului algoritmului în condiții apropiate de o inspecție reală, unde imaginea nu conține doar BGA-ul izolat, ci și alte structuri care pot influența procesarea.

Imaginile au fost organizate în folderul Images_BGA, iar imaginea brută a fost păstrată în directorul Raw. Rezultatele intermediare și finale au fost salvate separat în folderele Processed, ROI, Masks și Results. Această organizare a permis compararea imaginii originale cu rezultatele generate de fiecare etapă a algoritmului. Conform metodologiei proiectului, imaginile X-ray 2D sunt utilizate pentru inspecția nedistructivă a îmbinărilor BGA, iar voidurile sunt analizate doar în interiorul fiecărui solder ball. În figurile 2 este prezentată o imagine brută ce urmează să fie supusă procesării.




Figura 2. Captura cu PCBA2_04

6.2 Rezultate pentru detecția ROI-ului BGA

Prima etapă importantă a testării a fost identificarea automată a regiunii BGA. În imaginile analizate, BGA-ul nu apare întotdeauna perfect centrat și poate fi înconjurat de trasee sau alte componente cu intensitate ridicată. Din acest motiv, algoritmul nu se bazează pe coordonate fixe, ci încearcă să determine zona de interes pornind de la distribuția pad-urilor detectate. Rezultatele obținute arată că ROI-ul BGA poate fi determinat corect atunci când pad-urile formează o structură densă și regulată. Această etapă este importantă deoarece limitează analiza la zona relevantă și reduce riscul ca elemente externe, cum ar fi traseele PCB sau vias-urile, să fie incluse în detecția ulterioară. În testele efectuate, stabilizarea ROI-ului a fost una dintre etapele esențiale pentru obținerea unei grile coerente de pad-uri. În figura 3, este prezentată această detecție, pentru aceeași placă PCBA2_04. În următorul pas, acum, tot ce este în afara pătratului albastru, va fi ignorat de algoritm.




Figura 3. Captura în urma detecției ROI-ului

6.3 Rezultate pentru detecția pad-urilor BGA

După identificarea regiunii BGA, algoritmul detectează pad-urile/solder balls utilizând caracteristicile lor circulare și distribuția regulată. În această etapă au fost observate atât rezultate bune, cât și cazuri în care anumite structuri din imagine puteau fi confundate cu pad-uri reale. Cele mai frecvente probleme au apărut în zonele de margine ale BGA-ului și în zonele unde traseele PCB se suprapun vizual peste pad-uri. Pentru reducerea acestor erori, detecția pad-urilor a fost completată cu verificări geometrice și cu regularizarea grilei. Astfel, nu este suficient ca un candidat să aibă formă circulară, ci trebuie să se potrivească și în structura generală a BGA-ului. Această abordare este justificată de faptul că, în cazul BGA, pad-urile au o distribuție repetitivă, iar această proprietate poate fi folosită pentru eliminarea detecțiilor false. În jurnalul de testare al proiectului, stabilizarea contururilor pad-urilor a fost tratată ca o etapă separată, înainte de rafinarea detecției voidurilor. În figura 4 avem prezentat un exemplu de rezultat.




Figura 4. Rezultatul în urma detectării pad-urilor

6.4 Validarea grilei 16x16

Pentru imaginile analizate, structura BGA urmărită a fost o grilă de tip 16x16, corespunzătoare unui număr maxim de 256 de poziții. Validarea acestei grile are rolul de a verifica dacă pad-urile detectate sunt coerente atât ca poziție, cât și ca distanță între ele. O detecție izolată nu este acceptată automat, ci este raportată la pozițiile așteptate în grilă. Rezultatele obținute arată că regularizarea grilei ajută la corectarea unor detecții instabile și la menținerea unei structuri uniforme. În cazul în care anumite poziții sunt mai slab vizibile, acestea pot fi tratate ca poziții estimate doar dacă există suficientă evidență locală. Această etapă este importantă deoarece analiza voidurilor depinde direct de localizarea corectă a fiecărui solder ball. Dacă grila este incorectă, ROI-urile extrase ulterior pot fi deplasate, ceea ce afectează segmentarea și calculul procentului de voiding.

6.5 Exemple de detecție a voidurilor medii și mari

O observație importantă care rezultă din analiza imaginilor este aceea că voidurile voluminoase au rareori o morfologie perfect sferică. Datorită dinamicii de solidificare a pastei de lipit în timpul procesului de reflow, bulele de gaz adiacente tind să convergă, formând structuri organice, neregulate sau lobulare. Algoritmul propus abordează această particularitate prin abandonarea constrângerilor de circularitate strictă în favoarea unei segmentări bazate pe intensitatea contrastului radiografic. Această abordare permite o decupare fidelă a defectului fizic real, indiferent de complexitatea conturului său. În figura 5 avem un exemplu de zonă cu void-uri. Este important de remarcat modul în care algoritmul de detecție urmărește cu fidelitate marginile reale ale defectului, indiferent de forma acestuia, bazându-se pe gradientii de intensitate radiografică (zonele mai luminoase). Faptul că sistemul nu forțează o încadrare circulară aproximativă a zonei afectate este

esențial pentru o evaluare corectă conform standardului IPC-7095. Astfel, aria totală calculată reflectă volumul real de gaz captiv în structura bilei, eliminând riscul de subestimare a procentului de voiding. În plus, pe lângă formațiunea principală, algoritmul identifică simultan și incluziunile satelit de mici dimensiuni (punctul roșu izolat), contribuind la un calcul procentual exhaustiv.




Figura 5. Zonă cu voiduri detectate în urma rulării algoritmului

6.6 Calculul procentului de voiding

Evaluarea procentuală a voiding-ului reprezintă una dintre cele mai frecvente surse de confuzie în inspecția vizuală a ansamblurilor BGA, fenomen cauzat de o percepție vizuală distorsionată a ariei. Noi, ca și oameni, tindem să estimeze gravitatea unui defect pe baza diametrului acestuia. Totuși, standardele de calitate și algoritmul implementat evaluează proporția defectului pe baza ariei totale. Deoarece aria variază proporțional cu pătratul razei, o incluziune de gaz a cărei lățime acoperă vizual 20% din diametrul unei bile de cositor va reprezenta, în calculele matematice, doar aproximativ 4% din suprafața totală a joncțiunii. Pentru a demonstra acuratețea acestui calcul și a elimina subiectivismul vizual, a fost dezvoltat un instrument demonstrativ care raportează numărul exact de pixeli aferenți voidului la numărul total de pixeli ai pad-ului, confirmând astfel corectitudinea proporțiilor generate. În Figura 6 este prezentat rezultatul execuției unui script de diagnoză, dezvoltat suplimentar, (`demo_pixel_math.py`), dezvoltat special pentru validarea independentă a măsurătorilor la nivel de pixel. Conform acestei figuri, algoritmul suprapune vizual datele brute extrase direct peste imaginea radiografică originală, facilitând o verificare transparentă și obiectivă a calculelor matematice. Din punct de vedere arhitectural, acest algoritm de validare urmărește același pipeline ca și sistemul principal de inspecție. Inițial, extrage regiunea de interes (pătratul albastru, ROI) aferentă unei singure joncțiuni BGA și aplică algoritmii de filtrare morfologică și pragurile de contrast pentru a izola defectul. Diferența

majoră constă în modul de raportare a datelor. Pentru a demitiza iluzia optică a dimensiunii, scriptul extrage și afișează trei parametri fundamentali: Aria totală a joncțiunii: Delimitată vizual prin conturul circular verde, și transpusă în numărul total de pixeli alocați pad-ului. Aria efectivă a voidului: Elementele identificate ca fiind incluziuni de gaz sunt segmentate prin masca de culoare roșie. Algoritmul parcurge această mască și însumează strict numărul de pixeli aferenți defectului, fără a face aproximații geometrice ale formei (care este adesea asimetrică). Raportul matematic absolut: Este generat prin împărțirea directă a pixelilor roșii la pixelii totali ai pad-ului.




Figura 6. Rezultatul script-ului pentru validare

6.7 Cazuri dificile și limitări observate

Implementarea și testarea algoritmului de detecție au scos în evidență o serie de mari provocări tehnice specifice imaginilor X-Ray 2D. Principala sursă de rezultate fals-pozitive a fost reprezentată de traseele de cupru de pe suprafața PCB-ului. Deoarece razele X aplatizează structura tridimensională într-o proiecție 2D, marginile acestor trasee care se intersectează cu pad-urile generează gradienti de luminozitate similari cu cei ai voidurilor. Soluționarea acestei limitări s-a realizat prin introducerea unui filtru geometric bazat pe factorul de alungire. Astfel, formațiunile cu o disproporție semnificativă între lungime și lățime au fost clasificate drept elemente de cablaj și excluse din masca de defecte. Suplimentar, zgomotul de fond al senzorului și halourile luminoase au fost atenuate prin calibrarea pragurilor de contrast și aplicarea tehnicilor de morfologie matematică. O altă limitare observată în timpul dezvoltării este legată de variațiile de contrast dintre imaginile analizate. În funcție de poziția probei, grosimea locală a materialului și setările de achiziție

X-ray, aceleași structuri BGA pot apărea cu intensități diferite. Din acest motiv, un set fix de praguri nu garantează rezultate identice pentru toate imaginile. Pentru a reduce problema aceasta, algoritmul utilizează metode locale de preprocesare și segmentare, însă ajustarea parametrilor rămâne necesară în cazul unor imagini cu expunere neuniformă sau cu contrast foarte scăzut.

Un caz dificil a fost reprezentat de pad-urile aflate la marginea regiunii BGA. În aceste zone, prezentat și în figura 7, contururile pot fi parțial suprapuse peste trasee, vias sau alte structuri metalice, iar forma circulară a pad-ului poate fi mai greu de identificat. Acest lucru poate produce fie detecții incomplete, fie contururi ușor deplasate față de poziția reală a solder ball-ului. Regularizarea grilei 16x16 a redus aceste erori, deoarece pozițiile pad-urilor nu au fost tratate independent, ci în raport cu structura geometrică generală a capsulei BGA.




Figura 7. Exemplu de limitare în procesul de dezvoltare

De asemenea, algoritmul este mai stabil pentru voidurile medii și mari decât pentru voidurile foarte mici. Voidurile de dimensiuni reduse pot avea intensități apropiate de zgomotul imaginii sau de textura locală a lipiturii, ceea ce face dificilă separarea lor sigură. Din acest motiv, componentele foarte mici au fost filtrate, pentru a evita raportarea unor puncte izolate ca defecte reale. Această alegere poate duce la ignorarea unor micro-voiduri, dar oferă rezultate mai curate și mai relevante pentru evaluarea generală a calității lipirii.

O ultimă limitare este faptul că metoda propusă se bazează pe procesare clasică de imagine și nu include un mecanism de învățare automată. Avantajul acestei abordări este transparența algoritmului, deoarece fiecare etapă poate fi urmărită și explicată. Totuși, performanța depinde de calitatea imaginii, de parametrii aleși și de particularitățile fiecărui PCB analizat. Din acest motiv, rezultatele obținute trebuie interpretate ca o evaluare

automată asistivă, care poate reduce timpul de analiză și poate evidenția zonele problematice, dar care nu înlocuiește complet validarea vizuală în cazurile-limită. De exemplu, considerăm figura 8 unde s-au detectat pad-uri cum era de așteptat:





Figura 8. Pad-uri detectate pentru un PCBA

Totuși, pentru aceeași placă, avem o variație ca și formă a voidurilor – dintr-o formă rotundă, ajunge spre elipsă. Algoritmul, trebuie atunci tratat corespunzător, pentru a fi adaptabil de exemplu pentru acest caz, prezentat în Figura 9 (voidul nu a reușit să fie detectat de algoritm. În urma unor ajustări de parametrii, s-a remediat parțial această problemă, dar în continuare mai pot apărea erori. În figura 10 avem un exemplu de zonă cu voiduri eliptice, sau diferite ca formă față de un void rotund, care au fost detectate.



Figura 9. Void având o formă eliptică



Figur 10. Voiduri eliptice detectate de algoritm

6.8 Interpretarea rezultatelor din punct de vedere al calității lipirii

În sfârșit, obiectivul final al extracției metricilor de voiding este evaluarea integrității structurale și electrice a ansamblului. Analiza formelor detectate, inclusiv a excrescențelor sau a prelungirilor asimetrice, indică adesea prezența unor canale de degajare a gazului solidificate înainte ca bula să poată părăsi complet joncțiunea. Deși aceste anomalii prezintă un aspect neregulat pe radiografii, ele constituie o consecință inerentă a procesului tehnologic. Interpretarea datelor a fost realizată în strictă concordanță cu standardul industrial IPC-7095. Acesta stipulează că viabilitatea unei joncțiuni BGA se evaluează exclusiv pe baza procentajului total din arie afectat de goluri. Conform clasei 3 de performanță (cea mai restrictivă), o joncțiune este considerată neconformă doar dacă aria cumulată a voidurilor depășește pragul de 25%. Prin urmare, identificarea unor defecte izolate de 3% până la 10% confirmă un proces de asamblare funcțional și stabil. În cadrul acestei lucrări, analiza cantitativă a fost realizată pe baza unor parametri măsurabili: aria totală a voidurilor, aria celui mai mare void, numărul de voiduri detectate și procentul de voiding raportat la aria fiecărui solder ball. Dintre acești parametri, procentul de voiding este cel mai relevant pentru interpretarea numerică, deoarece permite compararea directă a îmbinărilor indiferent de mici variații de dimensiune ale pad-urilor. Totuși, analiza nu se limitează doar la valoarea procentuală, deoarece două îmbinări cu același procent de voiding pot avea comportamente diferite dacă voidurile sunt distribuite uniform sau dacă există un singur gol de dimensiune mare [2], [7].

Din punct de vedere calitativ, rezultatele au fost interpretate prin încadrarea fiecărei bile într-una dintre categoriile PASS, REVIEW sau FAIL. Categoria PASS a fost asociată îmbinărilor în care procentul de voiding este redus și nu indică o abatere semnificativă. Categoria REVIEW a fost utilizată pentru cazurile aflate la limită, unde este recomandată verificarea vizuală a imaginii adnotate și a măștii binare. Categoria FAIL a fost atribuită situațiilor în care procentul de voiding depășește pragul de acceptabilitate sau când cel mai mare void individual poate indica o slăbire locală importantă a îmbinării.

Raportarea la standardul IPC-7095 oferă un reper tehnic pentru interpretarea rezultatelor, însă pragurile trebuie tratate cu atenție, deoarece cerințele pot varia în funcție de aplicație,

clasă de performanță și specificațiile interne ale producătorului. În literatura consultată sunt menționate limite de acceptabilitate în jurul valorii de 20-25% pentru voiding în solder balls BGA, aceste valori fiind utilizate frecvent ca repere pentru evaluarea calității lipirii [1], [2], [3]. În lucrarea de față, pragul de 25% a fost considerat o limită superioară de neconformitate, iar valorile mai mici, de exemplu între 3% și 10%, au fost interpretate ca indicii ale unui proces de lipire funcțional, în absența altor defecte vizibile. Este important de menționat că evaluarea calității lipirii nu trebuie realizată exclusiv printr-un singur prag numeric. Într-o inspecție reală, poziția voidului, forma acestuia, dimensiunea maximă individuală și repetabilitatea defectului pe mai multe bile pot influența decizia finală.

De exemplu, un void izolat de dimensiune mică poate fi acceptabil, în timp ce un void mare poziționat într-o zonă critică poate necesita analiză suplimentară, chiar dacă procentul total nu pare foarte ridicat. Din acest motiv, rezultatele generate de aplicație au fost analizate atât tabelar, prin raportul CSV /Excel, cât și vizual, prin imaginile adnotate și măștile binare.

În cazul aplicațiilor cu cerințe ridicate de fiabilitate, cum sunt cele din domeniul automotive, industrial sau biomedical, interpretarea rezultatelor trebuie să fie mai conservatoare. Chiar dacă o îmbinare se află sub limita generală de acceptabilitate, prezența unor voiduri mari, a unor forme alungite sau a unei distribuții neuniforme poate indica o instabilitate a procesului de lipire. Astfel, metodologia propusă nu are rolul de a înlocui complet decizia unui inspector sau cerințele specifice ale unei companii, ci de a oferi o evaluare automată, repetabilă și explicabilă, care poate evidenția rapid îmbinările ce necesită atenție suplimentară [18], [19]. Prin urmare, analiza finală a calității lipirii combină două direcții: analiza cantitativă, bazată pe valori numerice precum procentul de voiding, aria totală și aria maximă a voidurilor, și analiza calitativă, bazată pe interpretarea vizuală a formei, poziției și distribuției defectelor. Această abordare este potrivită pentru o metodă clasică de procesare a imaginilor, deoarece păstrează transparența deciziei și permite verificarea fiecărui rezultat intermediar.

7 CONCLUZII ȘI DIRECȚII VIITOARE

Lucrarea de față a avut ca obiectiv dezvoltarea unei metodologii pentru detecția și evaluarea voidurilor din îmbinările BGA, utilizând imagini X-ray și metode clasice de procesare a imaginilor. Alegerea acestei direcții a pornit de la necesitatea unei metode explicabile, ușor de urmărit și adaptabile, fără utilizarea algoritmilor de tip machine learning sau deep learning. Din acest motiv, accentul nu a fost pus doar pe obținerea unui rezultat final, ci și pe construirea unui flux complet de prelucrare, în care fiecare etapă să poată fi verificată vizual și cantitativ.

Implementarea algoritmului s-a dovedit a fi mai dificilă decât părea inițial, deoarece imaginile X-ray 2D conțin multe structuri suprapuse. Pe lângă solder balls, în imagine apar trasee de cupru, vias, pad-uri laterale, zone metalice dense și artefacte generate de achiziție. Toate aceste elemente pot produce detecții false, mai ales atunci când au intensități sau forme apropiate de cele ale voidurilor. O provocare importantă a fost stabilizarea detecției pad-urilor, în special spre marginile regiunii BGA, unde contururile pot fi influențate de traseele PCB și de variațiile de contrast.

Cu toate aceste dificultăți, lucrarea a reușit să propună și să implementeze un flux funcțional de analiză. Algoritmul pornește de la imaginea X-ray brută, aplică preprocesare prin CLAHE și filtru median, detectează regiunea BGA, regularizează grila de pad-uri 16 x 16, extrage regiuni individuale pentru fiecare solder ball și aplică segmentarea voidurilor prin thresholding adaptiv. Ulterior, măștile binare sunt rafinate prin operații morfologice, iar componentele detectate sunt analizate statistic pentru calculul numărului de voiduri, ariei totale, ariei celui mai mare void și procentului de voiding. Prin această abordare, rezultatul final nu este doar o imagine adnotată, ci și un raport numeric care poate fi interpretat obiectiv.

Un rezultat important al lucrării este faptul că metodologia propusă permite o evaluare atât cantitativă, cât și calitativă a îmbinărilor BGA. Analiza cantitativă se bazează pe parametri măsurabili, precum procentul de voiding, aria totală a voidurilor și dimensiunea celui mai mare void. Analiza calitativă completează aceste valori prin interpretarea vizuală a formei, poziției și distribuției defectelor. Astfel, o îmbinare poate fi încadrată într-o categorie de tip PASS, REVIEW sau FAIL, în funcție de pragurile stabilite și de severitatea defectelor detectate. Această combinație între valori numerice și validare vizuală este importantă deoarece o simplă valoare procentuală nu descrie întotdeauna complet comportamentul real al defectului.

Metoda propusă are avantajul transparenței. Fiecare pas al algoritmului poate fi urmărit, ajustat și explicat. Spre deosebire de o abordare bazată exclusiv pe rețele neuronale, metoda clasică permite observarea directă a modului în care imaginea este preprocesată, cum sunt identificate pad-urile și ce regiuni sunt considerate voiduri.

Acest aspect este util într-un context de cercetare aplicată, unde este important ca rezultatele să poată fi justificate și corelate cu imaginea originală. În același timp, această transparență vine cu o limitare: performanța algoritmului depinde de calitatea imaginii, de contrast, de nivelul de zgomot și de parametrii aleși pentru fiecare etapă.

Direcțiile viitoare de dezvoltare trebuie să urmărească în primul rând îmbunătățirea robusteții algoritmului. O primă direcție ar fi extinderea setului de imagini de test, astfel încât metoda să fie validată pe mai multe tipuri de BGA, la scări diferite, cu expuneri diferite și cu niveluri variate de zgomot. O a doua direcție ar fi realizarea unui set de măști de referință, adnotate manual, care să permită calcularea unor metrici obiective de performanță, precum acuratețea segmentării, rata de detecții false și rata de voiduri omise. În acest fel, evaluarea algoritmului nu s-ar mai baza doar pe validare vizuală, ci și pe comparații cantitative cu un ground truth.

O altă îmbunătățire posibilă este automatizarea alegerii parametrilor. În forma actuală, pragurile de segmentare, dimensiunile filtrelor și criteriile geometrice sunt configurabile, dar pot necesita ajustări în funcție de imagine. În viitor, aceste valori ar putea fi adaptate automat pe baza histogramei locale, a contrastului sau a dimensiunii estimate a pad-urilor. Această optimizare ar reduce timpul de calibrare și ar face aplicația mai eficientă în cazul rulării pe loturi mai mari de imagini.

Pe termen mai lung, metodologia poate fi extinsă prin integrarea unor metode moderne bazate pe inteligență artificială. În literatura recentă, metodele de machine learning și deep learning sunt utilizate tot mai des pentru detecția defectelor în imagini X-ray, inclusiv prin arhitecturi de segmentare precum U-Net, CNN-uri sau modele hibride [8], [9], [19]. Aceste metode pot fi utile mai ales în cazurile dificile, unde contrastul este scăzut, voidurile sunt mici sau fundalul imaginii este complex. Totuși, utilizarea AI presupune existența unui set suficient de mare de date adnotate, precum și o validare atentă pentru a evita rezultate greu de explicat sau dependente de un anumit set de imagini.

O direcție interesantă este combinarea metodei clasice propuse în această lucrare cu metode AI. De exemplu, algoritmul clasic poate fi folosit pentru localizarea regiunii BGA și extragerea ROI-urilor, iar o rețea neuronală poate fi aplicată ulterior doar pe regiunile individuale ale solder balls. În acest mod, zona de analiză este restrânsă, iar modelul AI primește informație mai relevantă și mai puțin zgomot de fundal. O astfel de abordare hibridă ar putea păstra o parte din explicabilitatea metodei clasice, dar ar putea crește capacitatea de detecție în situațiile în care metodele de thresholding nu sunt suficiente. De asemenea, direcțiile moderne de cercetare nu se limitează doar la analiza imaginilor X-ray. În zona de producție electronică și testare End-of-Line, metodele de AI/ML pot fi folosite pentru optimizarea fluxurilor de testare, reducerea timpului de test și identificarea timpurie a instabilităților de proces.

Studii recente arată că selecția adaptivă a testelor poate reduce semnificativ timpul de testare în etape precum Functional Circuit Test și End-of-Line Testing, menținând în același timp controlul asupra riscului de defecte scăpate [20]. Alte cercetări folosesc deep learning pentru segmentarea seriilor temporale din cicluri industriale de testare EOL, demonstrând că datele colectate în producție pot fi utilizate pentru interpretarea automată a comportamentului produsului în timpul testării [21].

Prin urmare, lucrarea poate fi considerată un punct de plecare pentru dezvoltarea unei soluții mai complexe de inspecție automată. Varianta implementată demonstrează că metodele clasice de procesare a imaginilor pot oferi rezultate utile și explicabile pentru detecția voidurilor în BGA, mai ales atunci când fluxul este bine organizat și fiecare etapă este validată vizual. În același timp, limitările observate arată clar că există spațiu pentru îmbunătățire, atât prin optimizarea parametrilor și extinderea setului de test, cât și prin integrarea unor metode moderne bazate pe AI, ML și DL.

BIBLIOGRAFIE

- [1] A. Alakayleh, M. E. A. Belhadi, S. Tahat, E. HMasha, A. Shmatok, A. Alahmer și S. Hamasha, *Effect of Solder Paste Alloy and Volume on Solder Voiding*, în 2023 22nd IEEE Intersociety Conference on Thermal and Thermomechanical Phenomena in Electronic Systems (ITherm), Orlando, FL, USA, 2023, pp. 1-8, doi: 10.1109/ITHERM55368.2023.10177534.
- [2] C. Chao, W. Haolin, H. Shengzong, C. Ziwen, Z. Yun și H. Liang, *An Algorithm Based on K-Means for Calculating Void Ratio of Solder Joint from X-ray Image*, în 2022 23rd International Conference on Electronic Packaging Technology (ICEPT), 2022, pp. 1-4, doi: 10.1109/ICEPT56209.2022.9873214.
- [3] T. Chvosta, K. Dušek și T. Gurčík, *Occurrence of Voids in Soldered Joints for Electrical Engineering*, în 2024 47th International Spring Seminar on Electronics Technology (ISSE), Prague, Czech Republic, 2024, pp. 359-363, doi: 10.1109/ISSE61612.2024.10603930.
- [4] J. C. Faes, M. N. Boone, J. Vijayakumar, N. Lammens și W. Van Paepegem, *Quantitative, Statistically Robust Characterization of Solder Joint Geometry and Voids in Commercial BGA Assemblies*, în 2026 27th International Conference on Thermal, Mechanical and Multi-Physics Simulation and Experiments in Microelectronics and Microsystems (EuroSimE), 2026, doi: 10.1109/EuroSimE69483.2026.11511892.
- [5] O. Kováč, T. Girasek și A. Pietriková, *Image Processing of Die Attach's X-Ray Images for Automatic Voids Detection and Evaluation*, în 2016 39th International Spring Seminar on Electronics Technology (ISSE), Pilsen, Czech Republic, 2016, pp. 199-203, doi: 10.1109/ISSE.2016.7563188.
- [6] O. Krammer, Á. Varga, A. Géczy și K. Csorba, *Image Processing Methods for Detecting Voids in the Solder Joints of Surface-Mounted Components*, în 2022 45th International Spring Seminar on Electronics Technology (ISSE), 2022, pp. 1-4, doi: 10.1109/ISSE54558.2022.9812775.

- [7] S. P. Lim, K. O. Lee, K. Oi, Y. Yeo, K. Sweatman, T. Ono, K. Murayama, S. R. Martell, H. Shimamoto și M. Tsuruya, *The Effects of Voids on Solder Joint Reliability in First Level Interconnect*, în 2022 17th International Microsystems, Packaging, Assembly and Circuits Technology Conference (IMPACT), 2022, pp. 1-4, doi: 10.1109/IMPACT56280.2022.9966698.
- [8] M. A. Mercioni, C. D. Căleanu și R. C. Ionel, *AI-Enhanced X-ray Computed Tomography for Microelectronics: A Brief Review of Machine Learning and Deep Learning Integration in Non-Destructive Failure Analysis*, în 2026 International Conference on Development and Application Systems (DAS), Suceava, Romania, 2026, doi: 10.1109/DAS69882.2026.11553319.
- [9] M. H. Mohd Sa'at, M. H. Jamaluddin, M. I. M. Ameerudin, A. Z. Shukor, T. A. Izuddin, M. M. Ibrahim și M. S. Sukiman, *Integration Artificial Intelligence with Conventional X-Ray Inspection for Improved Solder Void Detection in SSDC SiC Modules*, în 2024 IEEE International Conference on Artificial Intelligence in Engineering and Technology (IICAET), 2024, pp. 530-534, doi: 10.1109/IICAET62352.2024.10730272.
- [10] S. P. Prasad, C. Jois și G. Subbarayan, *Novel Test Device for Non-destructive Experimental Characterization of Void Evolution in Microscale Solder Joints Subjected to Thermal Aging*, în 2022 21st IEEE Intersociety Conference on Thermal and Thermomechanical Phenomena in Electronic Systems (iTherm), San Diego, CA, USA, 2022, pp. 1-8, doi: 10.1109/iTherm54085.2022.9899684.
- [11] S. P. Prasad, C. Jois, Y. Singh, G. Subbarayan, B. Penmecha și P. Raghavan, *Void Growth and Intermetallic Bridging in Microscale Solder Interconnects Under Thermal Annealing*, IEEE Transactions on Components, Packaging and Manufacturing Technology, vol. 14, nr. 7, pp. 1308-1318, 2024, doi: 10.1109/TCPMT.2024.3416430.
- [12] H. Tang, W. Li, J. Nie, W. Liang, N. Cai și J. Chen, *Multi-Scale Adaptive Inspection Framework for Voids in MOSFETs*, IEEE Transactions on Semiconductor Manufacturing, vol. 38, nr. 4, pp. 826-839, 2025, doi: 10.1109/TSM.2025.3604212.
- [13] F. Wang și F. Wang, *Rapidly Void Detection in TSVs With 2-D X-Ray Imaging and Artificial Neural Networks*, IEEE Transactions on Semiconductor Manufacturing, vol. 27, nr. 2, pp. 246-251, 2014, doi: 10.1109/TSM.2014.2309591.
- [14] P. Xiao, M. Xiao, N. Cai, B. Qiu, S. Zhou și H. Wang, *Adaptive Hybrid Framework for Multiscale Void Inspection of Chip Resistor Solder Joints*, IEEE Transactions on Instrumentation and Measurement, vol. 72, art. nr. 5004612, pp. 1-12, 2023, doi: 10.1109/TIM.2023.3235435.
- [15] *** Waygate Technologies, *Phoenix V|tome|x S240 microCT: The Versatile Industrial 2D Radiography and 3D CT System for High Resolution Inspection with Improved Features and Design*, Baker Hughes Company, 2020.
- [16] G. Pandey and A. Vora, *Open Electronics for Medical Devices: State-of-Art and Unique Advantages*, Electronics, vol. 8, no. 11, art. no. 1256, 2019, doi: 10.3390/electronics8111256.
- [17] J. Bath, R. Garcia, N. Uchida, H. Takahashi, G. Clark and M. Itoh, *Investigation and Development of Tin-Lead and Lead-Free Solder Pastes to Reduce the Head-in-Pillow Component Soldering Defect*, SMTA International Conference Proceedings, 2009.

- [18] V. Ahuja and V. K. Neeluru, Robust BGA Void Detection Using Multi Directional Scan Algorithms, arXiv:1909.00211, 2019.
- [19] V. K. Neeluru and V. Ahuja, Void Region Segmentation in Ball Grid Array Using U-Net Approach and Synthetic Data, arXiv:1907.04222, 2019.
- [20] N. Haneefa, T. Lazebnik și E. Peretz-Andersson, Quality-preserving Model for Electronics Production Quality Tests Reduction, arXiv:2604.06451, 2026.
- [21] S. Gaugel și M. Reichert, PrecTime: A Deep Learning Architecture for Precise Time Series Segmentation in Industrial Manufacturing Operations, arXiv:2302.10182, 2023.

**DECLARAȚIE DE AUTENTICITATE A
LUCRĂRII DE FINALIZARE A STUDIILOR***

Subsemnatul MATALEA ANDREI

legitimat cu CI seria ES nr. 658078

CNP 501081115173

autorul lucrării METODOLOGIE PENTRU ESTIMAREA NEEQUILIBRIILOR PROBABILE
ALE PROCESELOR DE 4PIRE PE BAZA MORFOLOGIEI UNIDIMENSIONALE ÎN AGOURUL DE CĂRE ÎN BGA

elaborată în vederea susținerii examenului de finalizare a studiilor de MASTER

organizat de către Facultatea ELECTRONICĂ, TELECOMUNICAȚII ȘI TEHNologii INFORMATICI din cadrul Universității

Politehnica Timișoara, sesiunea Iunie 2026 a anului universitar 2025-2026, coordonator IONEL RAUL, luând în

considerare art. 34 din Regulamentul privind organizarea și desfășurarea examenelor de licență/diplomă și disertație, aprobat prin HS nr. 109/14.05.2020 și cunoscând faptul că în cazul constatării ulterioare a unor declarații false, voi suporta sancțiunea administrativă prevăzută de art. 146 din Legea nr. 1/2011 – legea educației naționale și anume anularea diplomei de studii, declar pe proprie răspundere, că:

- această lucrare este rezultatul propriei activități intelectuale;
- lucrarea nu conține texte, date sau elemente de grafică din alte lucrări sau din alte surse fără ca acestea să nu fie citate, inclusiv situația în care sursa o reprezintă o altă lucrare/alte lucrări ale subsemnatului;
- sursele bibliografice au fost folosite cu respectarea legislației române și a convențiilor internaționale privind drepturile de autor;
- această lucrare nu a mai fost prezentată în fața unei alte comisii de examen/prezentată public/publicată de licență/diplomă/disertație;
- În elaborarea lucrării am utilizat instrumente specifice inteligenței artificiale (IA) și anume ChatGPT (denumirea) OpenAI (sursa), pe care le-am citat în conținutul lucrării/nu am utilizat instrumente specifice inteligenței artificiale (IA)¹.

Declar că sunt de acord ca lucrarea să fie verificată prin orice modalitate legală pentru confirmarea originalității, consimțind inclusiv la introducerea conținutului său într-o bază de date în acest scop.

Timișoara,

Data

21.06.2026

Semnătura

MATALEA ANDREI

*Declarația se completează de student, se semnează olograf de acesta și se inserează în lucrarea de finalizare a studiilor, la sfârșitul lucrării, ca parte integrantă.

¹ Se va păstra una dintre variante: 1 - s-a utilizat IA și se menționează sursa 2 – nu s-a utilizat IA